

Étude de faisabilité d'un moteur de classification automatique d'articles

À partir des descriptions textuelles et des photographies de produits

Richard Hugou — Data Scientist junior
août 2026

Projet technique : github.com/richardhugou/product-category-classifier

Portfolio : portfolio.richardh.fr

1. Contexte et objectif de la mission

L'entreprise « Place de marché » prépare le lancement d'une marketplace en ligne anglophone, sur laquelle des vendeurs indépendants proposeront leurs articles à des acheteurs en publiant une photographie et une description.

Dans le fonctionnement prévu, chaque vendeur choisit lui-même la catégorie de son article au moment de la mise en ligne. Sur un catalogue réduit, cette organisation reste gérable. Elle devient plus difficile à tenir à mesure que le nombre de produits augmente : deux vendeurs peuvent classer des articles semblables à deux endroits différents, et un produit rangé au mauvais endroit devient plus difficile à retrouver. L'acheteur qui filtre par catégorie ne le voit pas, et le vendeur, lui, n'a aucun moyen de savoir pourquoi son article ne se vend pas.

Le volume d'articles est aujourd'hui faible, et c'est précisément ce qui rend le moment opportun : l'automatisation doit être en place avant que le catalogue grossisse. L'enjeu est double — faciliter la mise en ligne pour les vendeurs, et fiabiliser la recherche pour les acheteurs.

Linda, Lead Data Scientist, nous confie donc une étude de faisabilité, que nous menons en tant que Data Scientist junior. Il ne s'agit pas de construire ni de déployer le moteur définitif, mais de répondre à une question préalable dont dépend tout le reste : les informations déjà présentes dans une fiche produit — le texte de la description et la photographie — permettent-elles de retrouver automatiquement sa catégorie ?

Sa demande précise la démarche attendue, et celle-ci donne son plan au présent rapport. Il faut d'abord prétraiter les données textuelles et visuelles, puis en extraire des caractéristiques numériques selon plusieurs méthodes nommément désignées : pour le texte, un comptage simple de mots, une pondération TF-IDF, un embedding de mots de type Word2Vec, puis deux approches de représentation de phrase, BERT et USE ; pour l'image, une méthode à points d'intérêt de type SIFT et un réseau convolutif utilisé en transfert. Il faut ensuite projeter les produits en deux dimensions pour les observer, analyser graphiquement si les catégories se dessinent, et confirmer cette analyse visuelle par une mesure comparant les catégories réelles à une segmentation en clusters. Une seconde étape demande une classification supervisée à partir des images, optimisée par data augmentation. Une troisième, enfin, consiste à tester la collecte de produits d'épicerie fine via une API publique, dans la perspective d'élargir la gamme.

Une précision avant d'entrer dans le sujet. Nous travaillons sur un échantillon, avec des moyens de calcul modestes, et sur des données qui ont leurs propres défauts. Les conclusions valent pour ce périmètre, et nous signalerons à chaque fois ce qui se transpose à un catalogue réel et ce qui demanderait à être revérifié.

2. Découverte et préparation des données

Le jeu de données transmis par Linda contient 1 050 articles répartis dans 7 catégories, à raison de 150 produits chacune. Chaque article dispose d'une description rédigée en anglais par le vendeur et d'une photographie, ainsi que d'une quinzaine de champs annexes — prix, note, identifiants — que la mission ne retient pas puisqu'elle porte explicitement sur le texte et l'image.

Le meilleur moyen de comprendre ce jeu est d'en ouvrir une entrée. Prenons une montre, que nous garderons sous la main jusqu'à la fin de l'étude :

Champ	Contenu
<code>product_name</code>	V9 METAL STRAP Analog Watch – For Men
<code>description</code>	<i>Specifications of V9 METAL STRAP Analog Watch – For Men. General Type Analog. Style Code METAL STRAP. Occasion Casual. Ideal For Men. Warranty NO. Body Features Dial Shape Round. Strap Color STEEL. Dial Color BLACK.</i>
<code>product_category_tree</code>	<code>["Watches >> Wrist Watches >> V9 Wrist Watches >> ..."]</code>
<code>image</code>	une photographie de 1 152 × 1 816 pixels


La catégorie que nous cherchons à prédire n'est pas donnée directement : elle est enfouie dans une chaîne décrivant tout un chemin d'arborescence, mal formée, avec des guillemets échappés de façon incohérente. Nous en extrayons le premier niveau, ce qui produit les sept catégories annoncées — *Baby Care*, *Beauty and Personal Care*, *Computers*, *Home Decor & Festive Needs*, *Home Furnishing*, *Kitchen & Dining* et *Watches*. Descendre d'un niveau supplémentaire donnerait des dizaines de classes ne comptant que quelques produits, ce qui n'est pas exploitable à cette échelle. Notre cible est donc définie sans ambiguïté, mais sa fiabilité reste limitée : c'est le vendeur qui a choisi cette catégorie, et c'est précisément parce que ce choix est faillible que la mission existe. Nous y reviendrons au moment d'interpréter les résultats.

Ce que contiennent réellement les descriptions et les photographies

La description de notre montre illustre une caractéristique générale du corpus : ce ne sont pas des textes rédigés. Le vendeur a rempli un formulaire de spécifications, que la plateforme a aplati en une suite de mots. On y retrouve le nom du produit répété plusieurs fois, des paires attribut-valeur collées les unes aux autres, et parfois des fautes de frappe. Les descriptions comportent entre 13 et 587 mots, avec une médiane de 44.

Cette dispersion n'est pas répartie au hasard entre les catégories. Un article de *Home Furnishing* se décrit en 24 mots médians, un article de *Kitchen & Dining* en 88 — près de quatre fois plus. Les sept catégories sont donc parfaitement équilibrées en nombre de produits, mais pas du tout en quantité

d'information disponible. Ce point mérite d'être noté dès maintenant, car il explique en partie pourquoi certaines catégories seront plus difficiles à retrouver que d'autres.



Les photographies présentent une hétérogénéité comparable, sous une autre forme. Sur les 1 050 fichiers, on compte 890 tailles distinctes ; la plus fréquente, 1 100 × 844 pixels, ne concerne que 23 images. Les rapports largeur/hauteur s'échelonnent de 0,23 à 4,36, et le plus gros fichier atteint 93 mégapixels. Notre montre, avec ses 1 152 × 1 816 pixels, est un format vertical parmi beaucoup d'autres. Les méthodes d'extraction que nous emploierons ensuite attendent chacune un format d'entrée précis : les images devront donc être harmonisées en fonction de leurs contraintes respectives.

Ce que nous écartons, et comment nous préparons le reste

Un champ mérite une attention particulière avant d'aller plus loin. Le champ `brand` est renseigné pour 712 produits sur 1 050 ; il manque donc dans 32 % des cas. On serait tenté de le conserver et d'ajouter un indicateur signalant son absence, ce qui est une pratique courante. Ce serait ici une erreur, car ces valeurs manquantes ne sont pas réparties au hasard :

Catégorie	Marque absente
Watches	140 / 150
Beauty and Personal Care	109 / 150
Kitchen & Dining	71 / 150
Baby Care	16 / 150
Home Decor & Festive Needs	2 / 150
Computers	0 / 150
Home Furnishing	0 / 150

Parmi les 338 produits sans marque, 95 % appartiennent à trois catégories seulement, et aucun produit d'informatique ou d'ameublement n'a la case vide. Autrement dit, le seul fait que le champ soit vide renseigne fortement sur la catégorie — pour une raison qui tient aux habitudes de saisie des vendeurs et non à la nature des produits. Un modèle qui recevrait cette information apprendrait à lire cette habitude

plutôt que le produit, et ses performances s'effondreraient dès qu'un vendeur de montres se mettrait à renseigner sa marque. Nous écartons donc ce champ, indicateur d'absence compris.

Le prétraitement du texte suit ensuite une chaîne classique : passage en minuscules, suppression de la ponctuation et des chiffres isolés, découpage en mots, puis retrait des mots-outils anglais — *of, for, the* — qui apparaissent partout et ne distinguent rien. Appliquée à notre montre, cette chaîne ramène 34 mots bruts à 29 tokens retenus :

```
specifications · metal · strap · analog · watch · men · general · type · analog · style ·  
metal · strap · occasion · casual · ideal · men · warranty · body · features · dial · sha  
round · strap · color · steel · dial · color · black
```

Nous ne pratiquons ni racinisation ni lemmatisation. Sur un vocabulaire de fiches produit, `bedsheet` et `bedsheets` portent la même information et sont appris sans difficulté ; en revanche, tronquer les mots détruirait des références de modèles comme `7007YL08`, qui sont parfois les termes les plus discriminants d'une fiche.

Du côté des images, le traitement dépend de la méthode qui les consommera. Pour le réseau convolutif, chaque photographie est convertie en RGB, redimensionnée en carré de 224 pixels et normalisée selon les statistiques du jeu sur lequel ce réseau a été entraîné, faute de quoi ses représentations perdraient leur sens. Pour SIFT, qui travaille sur l'intensité lumineuse et non sur la couleur, les images sont converties en niveaux de gris, égalisées en contraste et ramenées à 256 pixels de côté. Une même photographie donne donc deux entrées différentes selon l'usage, ce qui est normal : la préparation n'est pas une étape neutre, elle est déjà un choix de méthode.

À ce stade, nous savons ce que contient le jeu, ce qu'il vaut et ce que nous en écartons. Il reste que ni une description ni une photographie ne peuvent être comparées directement à une autre par un algorithme, qui ne manipule que des nombres. C'est l'objet de la partie suivante.

3. Étude de faisabilité à partir du texte et des images

Linda demande de vérifier si les produits d'une même catégorie se regroupent spontanément une fois traduits en représentations numériques, et impose pour cela des méthodes précises : cinq pour le texte, deux familles pour l'image. Nous les appliquons toutes au même corpus et, pour pouvoir les comparer entre elles, à la même montre.

Une précision de protocole avant de commencer. Cette étude est non supervisée : les catégories ne servent qu'à colorier les graphiques et à mesurer l'accord final, jamais à construire les représentations. Nous pouvons donc les ajuster sur l'ensemble des 1 050 produits sans risquer la moindre fuite d'information. La question posée n'est pas encore « savons-nous prédire ? » mais « l'information est-elle présente ? ».

Représenter le texte

Le **comptage simple de mots** est la méthode la plus directe : on établit le vocabulaire du corpus, puis on compte combien de fois chaque mot apparaît dans chaque description. Le vocabulaire ainsi obtenu compte 2 444 mots, et chaque produit devient une liste de 2 444 nombres dont la grande majorité vaut zéro. Notre montre en a 22 non nuls, les plus élevés étant **strap** (3 occurrences), puis **analog**, **color**, **dial**, **men** et **metal** (2 chacun). C'est la référence la plus rudimentaire que l'on puisse construire, et c'est à ce titre qu'elle sert : toutes les méthodes qui suivent devront justifier leur coût par rapport à elle.

Une première variante consiste à compter aussi les paires de mots, ce qui permet de distinguer *round strap* de *round* et *strap* pris séparément. Le vocabulaire passe alors à 5 000 termes, et notre montre à 42 valeurs non nulles. Nous conservons les deux versions, précisément parce que seule cette option change de l'une à l'autre : l'écart entre elles ne peut donc venir que des paires.

Le **TF-IDF** reprend ce comptage et le pondère par la rareté du terme dans le corpus : un mot présent dans toutes les fiches ne distingue rien et doit peser peu. L'effet se lit directement sur notre montre. Le terme **color**, qui arrivait en tête avec le comptage simple, disparaît des premiers rangs parce qu'il apparaît dans presque toutes les fiches du catalogue, quelle que soit la catégorie. Ce sont **metal** et **strap** qui dominent :

Terme	Comptage simple	TF-IDF
strap	3	0,246
metal	2	0,272
color	2	<i>sort du classement</i>
dial	2	0,199
strap analog	1	0,215
round strap	1	0,181

De la fiche produit à la catégorie — la chaîne de transformation

1 • Description brute

55 mots, texte commercial libre

« Maxima 07034LMLI Attivo Analog Watch - For Women - Buy Maxima...
Rs.641 in India Only at Flipkart.com. Brass Case, Buckle Clasp... »



2 • Normalisation

minuscules · ponctuation · mots-outils anglais retirés

maxima · 07034lml · attivo · analog · watch · women · buy ... → 85 jetons retenus



3 • Vocabulaire

n-grammes 1-2 · terme vu au moins 2 fois · plafond 5 000

4 532 termes retenus sur l'ensemble du corpus d'entraînement



4 • Pondération TF-IDF

fréquence sublinéaire × rareté dans le corpus

vecteur creux : 61 termes non nuls sur 4 532

attivo 0,33 · attivo analog 0,33 · maxima 0,25 · watch women 0,21



5 • Classification

perceptron 128 → 64 → 7, sortie softmax

Watches 97,7 % · Home Decor 0,8 % · Beauty 0,7 % → catégorie réelle : Watches

Un article du jeu de test suivi de bout en bout. Chaque étape est ajustée sur les 735 articles d'entraînement seulement, jamais sur le test.

Ces deux représentations partagent une propriété précieuse : chaque dimension correspond à un terme que l'on peut nommer, ce qui permettrait plus tard d'expliquer une décision. Elles partagent aussi une limite : elles ignorent le sens. Pour elles, *sofa* et *couch* sont deux dimensions étrangères l'une à l'autre, sans aucun lien.

C'est ce que les trois méthodes suivantes cherchent à corriger. **Word2Vec** apprend un vecteur par mot, de telle sorte que deux mots employés dans des contextes semblables se retrouvent proches ; la description devient la moyenne des vecteurs de ses mots, soit 300 nombres. Nous entraînons ce modèle sur nos 1 050 descriptions, ce qui est peu pour apprendre une sémantique — nous verrons que le résultat s'en ressent. **BERT** apporte un contexte : chaque mot reçoit une représentation qui dépend de ses voisins, si bien que *mouse* n'a pas le même vecteur dans une fiche informatique et dans une fiche animalerie. Nous utilisons le modèle tel quel, sans le réentraîner, et moyennons ses sorties pour obtenir 768 nombres par produit. **USE**, enfin, est entraîné à représenter une phrase entière plutôt que des mots que l'on moyennerait ensuite, et produit 512 nombres. Nous employons le modèle de référence publié par ses auteurs ; les précautions techniques que cela a demandées sont décrites en annexe C.

Représenter les images

SIFT procède tout autrement. Plutôt que de décrire l'image entière, il repère les points remarquables — coins, contrastes marqués, motifs — et décrit chacun par 128 nombres caractérisant son voisinage immédiat. Sur la photographie de notre montre, il en détecte 508. Le problème est que ce nombre varie d'une image à l'autre, alors qu'il nous faut des vecteurs de taille identique pour comparer les produits. La solution classique consiste à construire un vocabulaire visuel : on rassemble les 482 202 descripteurs extraits des 1 050 photographies, on les regroupe en 256 familles, et chaque image devient l'histogramme du nombre de ses points tombant dans chaque famille. C'est exactement la logique du sac de mots appliquée à l'image, avec des « mots visuels » à la place des termes.

Le **réseau convolutif en transfert** repose sur une idée différente. Nous prenons VGG16, entraîné à reconnaître un millier d'objets sur ImageNet, et nous lui retirons sa couche de classification finale. Ce qui reste est un extracteur : l'image entre, et il en sort 512 nombres qui résument ce que le réseau y a reconnu. Le réseau n'est pas réentraîné sur nos produits — nous réutilisons tel quel ce qu'il a appris ailleurs, ce qui est précisément le principe du transfert.


À ce stade, chaque produit existe sous sept formes numériques différentes, de 256 à 5 000 dimensions. Reste à savoir laquelle rapproche les produits d'une même catégorie.

Projeter et regarder

Un espace à 512 ou 5 000 dimensions ne se visualise pas. Nous le réduisons donc en deux temps : une analyse en composantes principales ramène d'abord chaque représentation à 50 dimensions en conservant l'essentiel de sa variance, puis t-SNE la met en plan. Ce second algorithme cherche à préserver les voisinages plutôt que les distances globales, ce qui a une conséquence de lecture importante : sur les graphiques qui suivent, la proximité entre deux points a un sens, mais ni l'échelle des axes ni la distance entre deux îlots éloignés n'en ont.

Une précaution a été nécessaire avant de projeter. Les descriptions n'ayant pas toutes la même longueur, un produit bavard occupe mécaniquement une position plus éloignée de l'origine qu'un produit laconique, alors que la longueur du texte ne dit rien de sa catégorie. Nous ramenons donc chaque produit à une longueur unitaire. La tentation inverse — standardiser chaque dimension pour qu'elles aient toutes la même variance — aurait été plus dommageable encore : sur 5 000 dimensions dont la plupart sont vides, elle revient à donner à un terme apparu trois fois dans tout le corpus le même poids qu'à un terme structurant. Nous l'avons d'abord fait, et l'accord mesuré sur la représentation TF-IDF complète tombait alors à 0,001, c'est-à-dire au niveau du hasard.

Projection des 1 050 produits — couleur : catégorie réelle



La lecture de ces graphiques est assez directe. Les représentations de texte produisent toutes une structure partielle : quelques îlots nettement colorés — les montres, l'informatique — et un centre où plusieurs catégories se mélangent. La projection issue de VGG16 est la plus organisée, avec des zones colorées larges et peu d'interpénétration. Celle de SIFT, à l'inverse, est un nuage homogène dans lequel aucune couleur ne se détache : les points de toutes les catégories y sont répartis uniformément.

Mesurer pour confirmer


L'œil peut se tromper, et une projection en deux dimensions déforme nécessairement. Linda demande donc une mesure, et nous procédons comme suit : nous masquons les catégories, nous laissons un algorithme de partitionnement (K-means) former sept groupes à partir des seules représentations, puis nous comparons ces groupes aux vraies catégories à l'aide de l'indice de Rand ajusté.

Cet indice compare deux découpages d'un même ensemble. Il vaut 1 lorsqu'ils coïncident et 0 lorsque leur accord n'excède pas ce que produirait le hasard. L'ajustement est essentiel ici : avec sept groupes de tailles voisines, deux découpages tirés au sort présentent déjà un accord apparent non négligeable, que l'indice brut compterait à tort comme un succès.

Un point mérite d'être souligné, car la confusion est facile et fausserait toute la lecture qui suit : **un indice de 0,51 ne signifie pas que 51 % des produits sont correctement catégorisés**. Ce n'est pas une proportion. C'est une mesure de correspondance entre deux partitions, et les groupes formés n'ont d'ailleurs pas de nom — rien ne dit *a priori* lequel correspond aux montres. La question posée à ce stade est seulement de savoir si le découpage produit sans étiquettes ressemble au découpage commercial, pas de compter des bonnes réponses.

Nous rapportons cette mesure deux fois. Une première sur la projection, puisque c'est elle que nous avons regardée et que la mission demande de confirmer l'analyse visuelle. Une seconde sur la représentation complète, avant réduction, car t-SNE déforme et il serait commode de ne retenir que le plus flatteur des deux chiffres.

Représentation	Source	Dimensions	Accord sur la projection	Accord avant réduction
CNN (VGG16)	image	512	0,510	0,540
USE	texte	512	0,440	0,333
TF-IDF	texte	5 000	0,325	0,214
Comptage + bigrammes	texte	5 000	0,316	0,227
BERT	texte	768	0,316	0,288
Comptage de mots	texte	2 444	0,306	0,270
Word2Vec	texte	300	0,300	0,207
SIFT	image	256	0,044	0,056



Quatre observations ressortent de ce tableau.

L'image l'emporte nettement, mais à condition d'être traitée par le bon outil. VGG16 atteint 0,510 quand SIFT ne produit qu'un accord très faible, proche du hasard, alors que les deux méthodes reçoivent exactement les mêmes photographies. L'écart s'explique : SIFT décrit des motifs locaux — un angle, une texture, un contraste — utiles pour reconnaître qu'une même scène a été photographiée deux fois, mais qui ne disent rien de ce qu'est l'objet. VGG16, entraîné à reconnaître des objets, produit une description de nature sémantique. C'est un résultat instructif sur le plan méthodologique : une méthode reconnue peut se révéler inadaptée non par manque de qualité, mais parce qu'elle répond à une autre question que la nôtre.


VGG16 est aussi la seule représentation dont l'accord est meilleur avant réduction qu'après. Les catégories y sont donc réellement séparées dans l'espace d'origine, et non révélées par le passage en deux dimensions. Pour les représentations textuelles, l'écart entre les deux colonnes va dans l'autre sens : la structure existe, mais elle est plus difficile à isoler directement. C'est là que la double mesure prend tout son sens — lue seule, la colonne de gauche aurait accordé aux méthodes textuelles une netteté que l'espace d'origine ne confirme pas.

Du côté du texte, USE se détache avec 0,440, tandis que les cinq autres méthodes se tiennent entre 0,300 et 0,325. Le résultat le plus frappant est que le comptage simple de mots (0,306) fait pratiquement jeu égal avec BERT (0,316), et le devance même dans l'espace complet — 0,270 contre 0,288 pour BERT, mais surtout contre 0,214 pour TF-IDF. Sur des fiches de spécifications, où le vocabulaire est très discriminant et la syntaxe quasi absente, comprendre le contexte n'apporte presque rien de plus que compter les mots. Word2Vec, entraîné sur seulement 1 050 descriptions, arrive dernier, ce qui était prévisible au vu du volume disponible.

L'apport des bigrammes, enfin, est ambigu. Ils font gagner un point sur la projection (0,306 → 0,316) mais en font perdre quatre dans l'espace complet (0,270 → 0,227). Multiplier par deux la taille du vocabulaire ne rend donc pas la structure plus nette ; cela la disperse. Le résultat n'était pas acquis d'avance, et il justifie d'avoir gardé les deux versions plutôt que d'ajouter les paires de mots par habitude.

Ce que l'étude établit

CNN (VGG16) — ce que l'algorithme retrouve seul



L'ARI compare les deux partitions ci-dessus. Il vaut 0 lorsque l'accord n'excède pas le hasard et 1 lorsqu'elles coïncident ; ce n'est pas une proportion de produits bien classés.

Le tableau croisé des sept groupes formés par VGG16 et des sept catégories réelles montre une correspondance de un à un : chaque catégorie a son groupe dominant, et aucun groupe n'en accueille deux majoritairement. L'informatique et les montres sont retrouvées à 87 % et 86 %, la beauté à 80 %.

Deux catégories résistent, et l'examen des produits concernés éclaire pourquoi. *Home Furnishing* se scinde presque en deux : 71 produits dans son groupe, 69 dans celui de *Baby Care*. En regardant ce que contient cette seconde moitié, on trouve des housses de coussin, des couettes, des tapis de bain — et dans le groupe *Baby Care* qui les accueille, des serviettes en coton, des ensembles pyjama pour bébé et

des protège-matelas. Ce groupe ne correspond à aucune des deux catégories : il rassemble des textiles imprimés photographiés à plat. L'algorithme a regroupé par matière et par mise en scène, ce qui est ce qu'on lui a demandé de faire, alors que la nomenclature du site regroupe par usage commercial. Une couette et un pyjama de bébé n'ont rien en commun pour un acheteur ; ils se ressemblent beaucoup pour un réseau de vision.

La même mécanique semble expliquer le second point faible, *Home Decor & Festive Needs*, dont 31 produits partent dans le groupe de l'ameublement : porte-clés en bois, statuettes, décorations murales — des objets décoratifs photographiés seuls, comme le sont beaucoup d'articles d'ameublement.

Nous pouvons donc répondre à la question de Linda. L'information nécessaire à la catégorisation est bien présente dans les données fournies, et elle l'est suffisamment pour que des groupes cohérents émergent sans qu'aucune étiquette n'ait été montrée. Les photographies traitées par un réseau pré-entraîné constituent la source la plus prometteuse, devant les descriptions textuelles. Quant aux confusions résiduelles, elles semblent tenir à un écart entre deux logiques de regroupement, l'une visuelle et l'autre commerciale — nous verrons dans la partie suivante si la supervision les résorbe.

4. Classification supervisée des images

L'étude précédente a montré que les caractéristiques extraites par un réseau convolutif organisent le catalogue sans qu'on ait eu besoin de montrer une seule étiquette. Linda demande maintenant d'aller plus loin sur cette piste : puisque l'information est présente dans les photographies, que devient la performance lorsqu'on entraîne réellement un modèle à prédire la catégorie ?

La question change de nature, et le protocole avec elle. Tant qu'on cherchait à savoir si des groupes existaient, tout le corpus pouvait servir, puisqu'aucune étiquette n'entrait dans le calcul. Il faut à présent réserver des produits que le modèle ne verra pas pendant son apprentissage, faute de quoi la performance mesurée ne dirait rien de son comportement sur un article nouveau. Nous découpons donc les 1 050 produits en trois parts stratifiées et fixées une fois pour toutes : 735 pour l'entraînement, 157 pour la validation, 158 réservés à l'évaluation finale.

Cette découpe en trois, plutôt qu'en deux, mérite qu'on s'y arrête, car elle a corrigé une erreur de notre part. Nous avons d'abord comparé plusieurs stratégies d'entraînement directement sur le jeu de test, puis retenu la meilleure. Le procédé paraît anodin, mais dès lors que le résultat du test oriente le choix suivant, ce jeu mesure la qualité de notre sélection autant que celle du modèle. Le jeu de validation existe précisément pour absorber ces comparaisons. Toutes les décisions qui suivent sont donc prises sur les 157 produits de validation, et le jeu réservé n'est ouvert qu'ensuite, avec le seul modèle retenu.

Le modèle lui-même reprend le réseau de la partie précédente. VGG16 conserve ses poids d'origine et sert d'extracteur ; seule une petite tête de classification est apprise par-dessus. C'est le protocole habituel du transfert, et le seul raisonnable ici : réajuster les 138 millions de paramètres du réseau sur 735 images conduirait à ce qu'il apprenne ces images plutôt que la tâche.

Le fonctionnement se résume simplement. La photographie entre dans le réseau figé, qui en produit 512 nombres ; la tête reçoit ces 512 nombres et rend 7 probabilités, une par catégorie. Sur la photographie de notre montre — qui appartient au jeu réservé et n'a donc jamais servi à l'apprentissage — la réponse est *Watches* — à ce stade, c'est-à-dire avant toute augmentation — avec une probabilité de 0,977, la deuxième catégorie la plus probable ne recueillant que 0,011. C'est un cas facile : une montre sur fond blanc ne ressemble à rien d'autre dans le catalogue.

Chercher à faire mieux : la data augmentation

Linda demande de mettre en place une data augmentation pour tenter d'améliorer le modèle. Le principe consiste à fabriquer artificiellement de nouvelles images d'entraînement en transformant celles dont on dispose : les retourner, les faire pivoter légèrement, les recadrer, en modifier le contraste. Le modèle voit ainsi plus d'exemples, et devrait apprendre à reconnaître un produit indépendamment de la façon dont il a été photographié.

Le choix des transformations n'est pas neutre. Nos images sont des photographies de catalogue, généralement centrées et cadrées de la même manière. Un retournement horizontal ou une légère

rotation restent plausibles — le même article aurait pu être photographié dans l'autre sens. Un retournement vertical, en revanche, produirait des images qu'on ne rencontrera jamais.


Nous testons quatre stratégies, et cette variété fait partie du raisonnement : conclure à partir d'un seul réglage laisserait ouverte l'objection qu'il était mal choisi. Une augmentation dite douce se limite au retournement horizontal et à une rotation de dix degrés. Une augmentation forte y ajoute un recadrage aléatoire, une rotation de quinze degrés et une variation de couleur. Chacune est appliquée quatre fois par image, et la version forte est aussi testée à huit fois pour observer l'effet du volume.

Stratégie	Images d'entraînement	F1 macro sur la validation
Augmentation douce ×4	3 675	0,828
Augmentation forte ×4	3 675	0,827
Sans augmentation	735	0,822
Augmentation forte ×8	6 615	0,815

Sur le jeu de validation, l'augmentation douce obtient le meilleur score, mais le gain de 0,006 point de F1 macro — soit moins d'un produit sur 157 — est trop faible pour conclure à une amélioration nette. Les transformations douces et fortes appliquées quatre fois donnent des résultats très proches de la référence. Une augmentation plus forte et répétée, en revanche, dégrade nettement la performance. Une explication possible tient à la nature très standardisée des photographies du catalogue : multiplier les transformations artificielles peut éloigner les images d'entraînement de la distribution réellement observée. C'est une hypothèse plausible, que ces quatre essais ne suffisent pas à démontrer.

Le résultat est en revanche plus intéressant lorsqu'on le regarde catégorie par catégorie, car l'augmentation n'est pas sans effet : elle déplace les erreurs.

Catégorie	Sans	Douce ×4	Forte ×4	Forte ×8
Baby Care	0,750	0,762	0,762	0,818
Home Decor & Festive Needs	0,739	0,776	0,792	0,773
Watches	0,818	0,851	0,864	0,818
Beauty and Personal Care	0,810	0,800	0,810	0,829
Kitchen & Dining	0,920	0,913	0,939	0,898
Computers	0,810	0,809	0,783	0,750
Home Furnishing	0,905	0,884	0,837	0,818



Baby Care, la catégorie la plus fragile sans augmentation, gagne près de sept points à mesure que l'augmentation s'intensifie. *Home Decor* progresse également. Mais *Computers* et *Home Furnishing* suivent le chemin inverse et perdent respectivement six et neuf points. La moyenne ne bouge pas parce que les gains et les pertes se compensent.

Ce constat suggère qu'une augmentation générique, appliquée uniformément à tout le catalogue, n'est probablement pas la meilleure stratégie. Les catégories ne réagissent pas de la même manière aux mêmes transformations, et des traitements adaptés aux types de produits mériteraient d'être explorés.

Nous retenons donc l'augmentation douce, qui arrive en tête selon la règle de sélection fixée d'avance, en sachant que son avantage n'est pas établi.

Le résultat sur le jeu réservé

Le choix étant figé, nous ouvrons les 158 produits mis de côté. Le modèle en classe correctement 137, soit une exactitude de 86,7 % et une F1 macro de 0,867. Vingt et une erreurs, donc, à partir des seules photographies.

Ce chiffre mérite d'être situé. Il est obtenu avec un réseau dont aucun poids n'a été réentraîné, sur 735 images d'entraînement, et sans utiliser une seule ligne de description. Pour une étude de faisabilité, c'est une démonstration solide que l'image seule porte une part importante de l'information.

Augmentation douce $\times 4$ — 158 produits de test, ouverts une seule fois
F1 macro 0,867

Catégorie réelle	Baby Care	Beauty & Personal Care	Computers	Home Decor & Festive Needs	Home Furnishing	Kitchen & Dining	Watches
	19	0	0	1	2	0	0
	1	18	0	0	1	1	1
	0	0	17	3	0	3	0
	1	0	0	21	0	1	0
	2	0	1	1	19	0	0
	0	0	0	1	0	21	0
Catégorie prédite	Baby Care	Beauty & Personal Care	Computers	Home Decor & Festive Needs	Home Furnishing	Kitchen & Dining	Watches
	0	0	1	0	0	0	22

La matrice de confusion prolonge directement l'analyse de la partie précédente. Les deux erreurs les plus nombreuses concernent *Computers*, dispersé vers *Home Decor* et *Kitchen & Dining* à trois reprises chacune. Mais l'échange le plus significatif est ailleurs : deux *Baby Care* sont prédits *Home Furnishing*, et deux *Home Furnishing* sont prédits *Baby Care*. C'est la confusion que le regroupement sans étiquettes avait déjà fait apparaître, lorsque les housses de coussin et les couettes se retrouvaient dans le même groupe que les serviettes en coton et les pyjamas de bébé.

Cette continuité est le résultat le plus instructif de cette partie. La réapparition de la même confusion dans deux approches très différentes — l'une sans étiquettes, l'autre supervisée — suggère qu'elle ne dépend pas uniquement du modèle employé, et qu'il existe une ambiguïté réelle entre certaines images de ces deux catégories. La supervision la réduit sans la faire disparaître.

5. Collecte de nouveaux produits via une API

La dernière demande de Linda est indépendante du modèle. La marketplace envisage d'élargir sa gamme à l'épicerie fine, et il s'agit d'éprouver la faisabilité de la collecte avant d'envisager quoi que ce soit d'autre : peut-on récupérer automatiquement des produits, avec les informations nécessaires ?

Deux sources étaient proposées. Nous retenons Open Food Facts, parce qu'elle ne demande aucune inscription : le script reste exécutable tel quel par un tiers, sans clé à transmettre ni compte à créer. Cette base est alimentée de façon collaborative, ce qui aura son importance au moment de lire les résultats.

Le fichier attendu doit contenir cinq champs — `foodId`, `label`, `category`, `foodContentsLabel` et `image` — qui sont ceux du schéma d'Edamam, l'autre source proposée. Il faut donc les faire correspondre aux champs d'Open Food Facts. Quatre correspondances sont évidentes : le code-barres tient lieu d'identifiant, le nom du produit de libellé, les catégories et l'adresse de l'image se transposent directement. La cinquième demande un jugement : `foodContentsLabel` désigne chez Edamam la composition d'un produit, dont `ingredients_text` est l'équivalent le plus proche. Cette correspondance est isolée dans un dictionnaire unique du script, de sorte qu'elle soit lisible et discutable plutôt que dispersée dans le code.

Un choix technique mérite d'être signalé. Plutôt qu'une recherche en texte libre, nous filtrons sur la catégorie « champagne ». Une recherche plein texte remonterait aussi tout ce qui mentionne le mot sans en être : vinaigres, sauces, arômes.

L'extraction produit bien les dix produits demandés. Les cinq champs sont renseignés dans presque tous les cas — la composition manque pour deux produits sur dix. Le fichier est utilisable en l'état.

Ce qu'il contient est plus instructif que le fait qu'il existe. Trois observations se dégagent.

Les catégories sont hétérogènes. Ces dix produits portent cinq étiquettes différentes : *Champagnes* pour cinq d'entre eux, *French Champagnes* pour trois, *fr:Champagnes bruts* pour trois, *fr:Champagnes rosés* et *fr:Liquide* pour un chacun. Certaines n'ont pas été traduites et conservent un préfixe de langue ; l'une d'elles, *fr:Liquide*, ne dit à peu près rien du produit.

Les libellés sont irréguliers. L'un d'eux se lit « Br MOË HANDON MOET & CHANDON CHAMPAGNE IMPERIAL BR », mélangeant caractères cyrilliques et fragments de texte — trace visible de la saisie collaborative et de la reconnaissance automatique d'étiquettes.

Enfin, la catégorie source n'est pas toujours juste. Parmi les dix champagnes figure un « MARTINI Bellini Peach 8,0 % vol », qui est un cocktail à la pêche.

Cette collecte reste exploratoire — dix produits ne permettent pas de caractériser une base entière — mais elle met déjà en évidence un enjeu de qualité et d'homogénéité des métadonnées, qui devra être traité en amont du modèle de classification. Établir une correspondance entre la nomenclature de la

marketplace et celles des sources externes, et composer avec des étiquettes source imparfaites, sont des travaux préalables à tout réentraînement.

On retrouve d'ailleurs, sous une autre forme, la difficulté du point de départ : ici comme sur la marketplace, les catégories sont déclarées par des contributeurs qui ne suivent pas tous la même règle.

6. Bilan, limites et perspectives

Ce que l'étude établit

La réponse à la question de Linda est positive. Les informations déjà fournies par les vendeurs — une description et une photographie — contiennent l'information nécessaire pour retrouver la catégorie d'un article.

Cette réponse tient sur deux démonstrations indépendantes. Sans utiliser une seule étiquette, un algorithme de regroupement retrouve une partition qui correspond substantiellement aux sept catégories du catalogue, avec un accord de 0,51 pour les caractéristiques visuelles issues d'un réseau pré-entraîné. Et en supervisé, à partir des seules photographies, un modèle classe correctement 137 des 158 produits réservés à l'évaluation finale.

Trois résultats méritent d'être retenus au-delà du chiffre principal.

Les représentations visuelles issues d'un réseau pré-entraîné sont ici plus informatives que les représentations textuelles, ce qui n'allait pas de soi sur des fiches produit détaillées. Le choix de la méthode compte davantage que celui de la modalité : sur les mêmes photographies, un réseau convolutif obtient 0,51 quand SIFT reste proche du hasard. Et du côté du texte, un simple comptage de mots se situe au niveau de représentations bien plus élaborées, ce qui s'explique par la nature des descriptions — des listes de spécifications, où le vocabulaire est très discriminant et la syntaxe presque absente.

Enfin, l'étude a identifié une difficulté que ni un meilleur modèle ni davantage de données ne résoudront seuls. Certaines catégories du catalogue regroupent des produits par usage commercial alors qu'ils sont visuellement très proches — une couette et un pyjama de bébé, un objet décoratif et un objet d'ameublement. Cette ambiguïté apparaît dans les regroupements non supervisés et se retrouve, atténuée, dans les erreurs du modèle supervisé.

Les limites

La plus profonde tient aux catégories elles-mêmes. Elles ont été saisies par les vendeurs, c'est-à-dire par ceux dont la mission cherche justement à corriger les erreurs. Nous entraînons et évaluons contre une référence imparfaite, sans moyen de savoir, lorsque le modèle contredit une étiquette, lequel des deux a raison. Toute performance rapportée ici est donc mesurée contre un étalon bruité.

Le volume constitue la deuxième limite. Mille cinquante produits, dont 735 pour l'entraînement, c'est peu. Cela nous a interdit le fine-tuning des réseaux pré-entraînés, qui sont donc employés figés : nous comparons des représentations, pas les capacités maximales de ces modèles. Cela explique aussi la contre-performance de Word2Vec, entraîné sur ce seul corpus.

Le jeu est par ailleurs parfaitement équilibré, avec exactement 150 produits par catégorie, ce qui n'arrive jamais dans un catalogue réel. Les conclusions demanderaient à être revérifiées sur une distribution naturelle, où certaines catégories seraient bien plus peuplées que d'autres. Nous n'avons enfin traité que le premier niveau de l'arborescence : sept catégories, là où le site en propose beaucoup plus une fois qu'on descend dans les branches.

Un mot sur le jeu réservé, par honnêteté de méthode. Le protocole appliqué dans sa version finale est correct — sélection sur validation, puis une seule évaluation. Il reste que ce jeu avait été consulté lors de la version antérieure et erronée du protocole, décrite en partie 4. Son indépendance historique n'est donc pas parfaite, même si le résultat rapporté, lui, découle bien d'une sélection faite sur la validation.

Ce que nous recommandons ensuite

La première étape n'est pas technique. Les confusions identifiées suggèrent que certaines frontières de la nomenclature sont ambiguës pour un humain lui-même : un bougeoir décoratif qui sert à table appartient-il à la décoration ou aux arts de la table ? Faire trancher ces cas par l'équipe catalogue, et faire ré-étiqueter un échantillon des produits sur lesquels le modèle est confiant tout en contredisant le vendeur, permettrait de savoir si les erreurs restantes sont celles du modèle ou celles du catalogue. Sans cette clarification, on optimiserait contre une cible bruitée.

Vient ensuite le volume. Un corpus plus important rendrait accessible le fine-tuning des réseaux pré-entraînés, qui est la piste la plus prometteuse pour dépasser le niveau atteint ici, et permettrait d'envisager une classification hiérarchique descendant dans l'arborescence.

Sur le plan technique, deux pistes se dégagent de nos observations. La combinaison du texte et de l'image n'a pas été exploitée dans le modèle supervisé, alors que les deux sources ne se trompent manifestement pas sur les mêmes produits ; une comparaison complémentaire d'approches combinées est disponible dans le dépôt ([benchmark.py](#)), en marge du périmètre de la mission. Et l'augmentation de données mériterait d'être reprise, non pas uniformément, mais avec des transformations choisies par type de produit : nos mesures montrent qu'une même augmentation aide certaines catégories et en dégrade d'autres.

Enfin, si la marketplace confirme l'ouverture à l'épicerie fine, le travail préalable portera sur la qualité et l'homogénéité des métadonnées des sources externes, avant même la question du modèle.

7. Conduite du projet

Comment nous avons travaillé

Le projet a avancé par questions successives, chacune tranchée par une mesure avant de passer à la suivante. Cette discipline a une conséquence pratique : à aucun moment nous n'avons construit une brique dont l'utilité n'était pas encore établie. La classification supervisée n'a été entreprise qu'une fois démontré, sans étiquettes, que l'information était présente dans les images ; la data augmentation n'a été mise en place qu'une fois le modèle de référence mesuré.

Chaque étape a laissé une trace exécutable. Le dépôt s'organise en branches thématiques fusionnées après relecture, et l'intégration continue rejoue à chaque modification la vérification de style, les tests unitaires, puis la chaîne complète depuis un clone vierge. Ce dernier point n'est pas cosmétique : il a révélé un défaut qu'aucune exécution locale n'aurait montré, les tests n'étant pas collectés depuis un clone propre alors qu'ils passaient sur notre machine.

Les délais et où le temps est passé

L'étude tient en une vingtaine de minutes de calcul sur un ordinateur portable, mais cette durée est très inégalement répartie. L'extraction des caractéristiques domine tout le reste : encoder les 1 050 photographies avec VGG16 et en extraire 482 202 descripteurs SIFT représente à elle seule l'essentiel du temps machine. Les projections, les segmentations et l'entraînement des têtes de classification se comptent en secondes.

Ce déséquilibre a orienté une décision d'architecture : toutes les caractéristiques extraites sont mises en cache sur disque. Une seconde exécution ne recalcule ni SIFT ni les réseaux, ce qui a rendu possible de reprendre plusieurs fois l'analyse sans repayer le coût d'extraction.

Deux postes ont coûté plus que prévu. La cohabitation de TensorFlow et PyTorch dans un même processus a bloqué l'exécution sans lever d'erreur, ce qui est le pire mode de défaillance : le programme paraît travailler. Le diagnostic a demandé d'isoler le modèle dans un processus séparé pour constater qu'il se chargeait en deux secondes. Et la reprise du protocole d'évaluation, décrite plus bas, a imposé de recalculer l'ensemble de la partie supervisée.

Les coûts

Le projet n'a engagé aucun coût d'infrastructure. Tout s'exécute sur un ordinateur portable, sans location de calcul graphique, et l'ensemble des modèles employés est librement disponible. Le poste le plus lourd est le téléchargement initial des poids pré-entraînés — environ trois gigaoctets —, payé une fois.

Le coût réel de cette étude est donc en temps de travail, et sa structure mérite d'être notée : la part consacrée à écrire du code de modélisation est minoritaire. L'essentiel est allé à comprendre les données, à choisir les protocoles de mesure et à vérifier que les chiffres produits voulaient dire ce qu'on croyait.

Sur une mise en production, la structure des coûts changerait de nature. L'inférence resterait modeste — quelques dizaines de millisecondes par article sur un processeur ordinaire — mais le traitement du catalogue existant, la construction d'un jeu d'étiquettes fiable et la maintenance de la chaîne deviendraient les postes dominants. Ce chiffrage dépasse le périmètre d'une étude de faisabilité et demanderait des données que nous n'avons pas : volume réel du catalogue, cadence de publication, coût horaire d'une révision manuelle.

Les livrables

Trois livrables répondent aux trois demandes. L'étude de faisabilité produit huit projections, un tableau d'accords et les figures associées. La classification supervisée produit un modèle mesuré, sa matrice de confusion et la comparaison des stratégies d'augmentation. La collecte produit le fichier des dix produits aux cinq champs demandés.

À cela s'ajoutent le présent rapport, six notebooks exécutés qui portent le détail du raisonnement, et un dépôt public qui se rejoue en trois commandes.

Le contrôle de la performance, et deux erreurs corrigées

Un rapport qui ne montrerait que ce qui a fonctionné ne rendrait pas compte du travail. Deux décisions ont été prises puis défaites, et les deux touchaient à la validité des mesures elles-mêmes.

La normalisation avant projection. La première version standardisait chaque dimension avant de réduire. Sur des représentations creuses de cinq mille dimensions, ce traitement donne à un terme apparu trois fois dans tout le corpus le même poids qu'à un terme structurant : l'accord mesuré pour TF-IDF tombait à 0,001, au niveau du hasard. Le défaut a été repéré parce que ce chiffre était trop mauvais pour être vrai — un score anormalement bas est un signal aussi utile qu'un score anormalement bon.

Le protocole de sélection. Plus grave, les stratégies d'augmentation ont d'abord été comparées directement sur le jeu de test, avant que la meilleure ne soit retenue. Aucune étiquette de test n'atteignait les poids du modèle, mais les décisions méthodologiques, elles, en dépendaient. Le jeu de validation existait et n'était pas utilisé. La correction a inversé la conclusion : la comparaison sur le test désignait l'absence d'augmentation, celle sur la validation désigne l'augmentation douce. C'est la meilleure justification qu'on puisse donner d'une règle de méthode — elle change la réponse.

Ces deux corrections ont un point commun. Ni l'une ni l'autre n'a été signalée par un test qui échoue : le code fonctionnait, il mesurait simplement autre chose que ce que nous croyions mesurer. C'est la raison pour laquelle chaque chiffre du présent rapport est accompagné du protocole qui l'a produit, et pourquoi certains sont rapportés deux fois — l'accord avant et après réduction, la performance sur la validation puis sur le jeu réservé.

Ce que ce projet nous a appris

Trois enseignements dépassent le cas particulier de cette marketplace.

Le choix de la représentation pèse plus que celui de l'algorithme. Sur les mêmes photographies, deux méthodes d'extraction donnent 0,510 et 0,044. Aucun réglage de classifieur ne comble un tel écart.

Une méthode reconnue peut être inadaptée sans être mauvaise. SIFT fait exactement ce pour quoi il a été conçu ; ce n'est simplement pas la question que nous posons. Savoir *pour quel usage* un outil a été construit importe davantage que sa réputation.

Le protocole de mesure fait partie du résultat. Les deux erreurs corrigées ci-dessus ne portaient pas sur les modèles mais sur la façon de les évaluer, et l'une d'elles changeait la conclusion. Un score sans son protocole n'est pas une information.

Annexes

A. Rejouer l'étude

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements-encoders.txt

python faisabilite.py      # les sept représentations, projections, K-means, ARI
python supervise_image.py  # classification supervisée et data augmentation
python collecte_api.py     # collecte « champagne » et fichier CSV
```

Le socle seul (`requirements.txt`) suffit pour l'exploration des données et les modèles classiques ; `requirements-encoders.txt` ajoute les réseaux pré-entraînés, soit environ 3 Go de poids au premier lancement. Les versions sont épinglées, la graine aléatoire est fixe, et la découpe des données est définie dans un module unique (`src/pipeline.py`) appelé par tous les scripts. Les caractéristiques extraites sont mises en cache sur disque : une seconde exécution ne recalcule ni SIFT ni VGG16.

B. Figures et fichiers produits

Fichier	Contenu
<code>reports/fig3_transformations.png</code>	La chaîne de transformation du texte, sur un article réel
<code>reports/fig4_donnees.png</code>	Équilibre des classes et distribution des longueurs
<code>reports/fig5_projections.png</code>	Les sept projections en deux dimensions
<code>reports/fig6_clusters.png</code>	VGG16 : catégories réelles et groupes trouvés
<code>reports/fig7_ari.png</code>	L'accord entre groupes et catégories, par représentation
<code>reports/fig8_confusion_image.png</code>	Matrice de confusion du modèle supervisé
<code>reports/fig9_augmentation_par_classe.png</code>	L'effet de l'augmentation, catégorie par catégorie
<code>reports/faisabilite.csv</code>	Dimensions et accords des sept représentations
<code>reports/supervise_image_validation.csv</code>	Comparaison des stratégies d'augmentation
<code>reports/supervise_image_test.csv</code>	Résultat final du modèle retenu
<code>reports/produits_champagne.csv</code>	Les dix produits collectés via l'API

C. Notes techniques

Universal Sentence Encoder et la cohabitation TensorFlow / PyTorch. USE est distribué pour TensorFlow, quand le reste de notre chaîne repose sur PyTorch. Les deux bibliothèques s'installent sans conflit de versions, mais chargées dans un même processus elles se sont bloquées mutuellement sur notre machine : la première exécution est restée figée sans lever d'erreur. Isolé dans son propre processus, le modèle se charge en deux secondes. L'encodage USE est donc délégué à un sous-processus dédié, ce qui permet d'employer le modèle de référence lui-même plutôt qu'une variante approchante. Par ailleurs, `tensorflow_hub` importe encore `pkg_resources`, retiré de `setuptools` à partir de la version 81 : la borne haute présente dans les dépendances est là pour cette seule raison.

Point d'entrée de l'API Open Food Facts. L'ancien point d'entrée `cgi/search.pl`, déprécié, a renvoyé une erreur de service temporairement indisponible lors du premier essai. Le script utilise le point d'entrée `v2`, maintenu, et réessaie avec une attente croissante plutôt que d'échouer sur un incident passager.

Normalisation avant projection. Chaque produit est ramené à une longueur unitaire avant l'analyse en composantes principales, ce qui rend la distance euclidienne équivalente à la distance cosinus. Une première version standardisait chaque dimension : sur des représentations creuses de 5 000 dimensions, ce traitement amplifiait les termes rares au point de ramener l'accord de TF-IDF au niveau du hasard.