

Automatisation de la catégorisation d'articles sur une place de marché

Rapport de conduite de projet AI Engineering

Richard Hugou · Data Scientist & AI Engineer
août 2026

Projet technique : github.com/richardhugou/product-category-classifier

Portfolio : portfolio.richardh.fr

1. Contexte et analyse des besoins

1.1 Contexte

Élément	État constaté
Activité	place de marché généraliste anglophone, mise en relation vendeurs et acheteurs
Modèle de mise en ligne	dépôt libre par le vendeur : une photographie, une description, une catégorie déclarée
Volume	catalogue en phase de croissance ; échantillon de travail de 1 050 articles sur 7 catégories
Maturité IA et MLOps	nulle. Aucun modèle en service, aucun indicateur de qualité du catalogue
Moyens de calcul	poste de travail local, sans accélérateur dédié

Enjeux : fluidifier la mise en ligne côté vendeur, fiabiliser le filtrage par catégorie côté acheteur. Le second dépend du premier : un article mal rangé n'est pas retrouvé par l'acheteur qui filtre, et le vendeur n'en est jamais informé. L'automatisation doit être disponible avant que le volume rende la correction manuelle impraticable.

Contraintes de départ : calcul local sans accélérateur ; aucune donnée personnelle dans le périmètre, mais des entrées non maîtrisées puisque fournies par les vendeurs ; solution devant tenir sur un catalogue d'un ordre de grandeur supérieur à l'échantillon ; aucune plateforme d'hébergement de modèle en place.

1.2 Besoin métier

Commanditaire : Lead Data Scientist. Utilisateurs concernés : vendeurs et équipe catalogue.

Recueil. Deux voies, sans atelier collectif :

1. **Brief écrit du commanditaire**, en trois demandes : établir la faisabilité à partir des données existantes, produire une classification supervisée à partir des images, éprouver la collecte de nouveaux produits via une interface externe.
2. **Analyse documentaire du jeu de données**, outillée : profilage des champs, des longueurs de description, des formats d'image, du taux de complétude (`scripts/profile_data.py`). Elle a fait remonter deux besoins absents du brief, la neutralisation du champ `brand` et l'harmonisation des formats d'image.

Objectifs.

Nature	Objectif	Traduction mesurable
Business	réduire le temps de mise en ligne	part du catalogue classée sans intervention humaine
Business	réduire les articles mal rangés	taux de propositions correctes sur la part automatisée
Technique	établir que la catégorie est déductible des données existantes	accord entre groupes non supervisés et catégories réelles
Technique	évaluer le modèle sur des données jamais vues	F1 macro et exactitude sur un jeu réservé

Contraintes.


Type	Contrainte	Conséquence retenue
Fonctionnelle	premier niveau de nomenclature uniquement, 7 catégories	granularité fine hors périmètre
Fonctionnelle	proposition, jamais imposition, de la catégorie	sortie probabiliste, décision séparée du modèle
Non fonctionnelle	latence compatible avec une mise en ligne interactive	mesure du coût d'inférence par article
Non fonctionnelle	reproductibilité des essais	découpe unique, graine fixe, versions épinglées
Organisationnelle	aucune équipe d'annotation disponible	pas de ré-étiquetage du corpus
Réglementaire	corpus sans donnée personnelle, images sous licence de recherche	usage d'étude ; une extension à des données vendeurs relèverait du RGPD
Éthique	étiquette de référence produite par les vendeurs	la performance mesurée est bornée par la qualité de cette référence

Périmètre retenu, ordonné par impact sur le besoin puis par effort de réalisation : faisabilité avant tout engagement ; classification à partir du texte et de l'image ; décision d'abstention et routage en revue humaine ; neutralisation des champs porteurs de fuite ; collecte externe. Hors périmètre : classification hiérarchique complète, réglage fin des extracteurs, interface de correction.

2. Audit de la solution existante

2.1 Processus en place

Aucune brique logicielle n'intervient entre le vendeur et le catalogue. La catégorie est saisie dans un formulaire libre, enregistrée telle quelle, puis utilisée comme clé de filtrage.



Composant	Nature	Outillage
Saisie	formulaire de mise en ligne	champ de nomenclature déclaratif
Stockage	catalogue produits	arborescence de catégories sur plusieurs niveaux
Restitution	recherche et filtres	filtrage exact sur le premier niveau
Contrôle qualité	aucun	ni règle partagée, ni revue, ni indicateur

Données disponibles par article : `product_name`, `description` rédigée par le vendeur, `product_category_tree`, une photographie, et une quinzaine de champs annexes hors périmètre.

Exemple de référence, conservé dans tout le rapport.


Champ	Contenu
<code>product_name</code>	V9 METAL STRAP Analog Watch – For Men
<code>description</code>	<i>Specifications of V9 METAL STRAP Analog Watch – For Men. General Type Analog. Style Code METAL STRAP. Occasion Casual. Ideal For Men. Warranty NO. Body Features Dial Shape Round. Strap Color STEEL. Dial Color BLACK.</i>
<code>product_category_tree</code>	<code>["Watches >> Wrist Watches >> V9 Wrist Watches >> ..."]</code>
<code>image</code>	photographie de 1 152 × 1 816 pixels

2.2 Audit des données et écarts

Démarche. Profilage descriptif de chaque champ, contrôle de la cible, contrôle des entrées. Référentiel appliqué : complétude, validité, cohérence, représentativité, absence de fuite. L'audit porte sur les données et sur le processus, aucun composant logiciel n'étant en place.

Cible. La catégorie n'est pas un champ, mais le premier niveau d'une chaîne d'arborescence mal formée, aux échappements incohérents. Son extraction produit les sept catégories du périmètre : *Baby Care*, *Beauty and Personal Care*, *Computers*, *Home Decor & Festive Needs*, *Home Furnishing*, *Kitchen & Dining*, *Watches*. Elle est déclarée par les vendeurs : la référence d'évaluation est elle-même faillible.

Entrées. Les descriptions sont des formulaires de spécifications aplatis, non des textes rédigés : 13 à 587 mots, médiane 44, longueur médiane variable selon la catégorie, de 24 mots pour *Home Furnishing* à 88 pour *Kitchen & Dining*. Les photographies présentent 890 tailles distinctes sur 1 050 fichiers, des ratios de 0,23 à 4,36, jusqu'à 93 mégapixels : harmonisation obligatoire.



Fuite détectée. Le champ `brand` présente 32 % de valeurs manquantes, et cette absence est fortement corrélée à la catégorie : 95 % des 338 absences se concentrent sur trois catégories, *Watches* (140 / 150), *Beauty and Personal Care* (109 / 150) et *Kitchen & Dining* (71 / 150). Un modèle recevant ce champ apprendrait une habitude de saisie, non le produit. Exclusion décidée, indicateur d'absence compris.

Écarts. Le processus en place a été évalué sur la justesse du classement, la validation des entrées, le coût et la maintenabilité.

Écart	Conséquence
Aucune mesure de justesse du catalogue	aucun pilotage possible, le défaut reste invisible
Aucune règle commune entre vendeurs	deux articles semblables classés à deux endroits
Entrées libres non validées	texte et image non contrôlés en entrée de chaîne

Aucun de ces écarts ne se corrige par un ajustement du formulaire.

3. Solution technique cible

3.1 Cas d'usage

Les cas d'usage sont dérivés du périmètre, puis cotés sur la valeur attendue, la faisabilité établie par la mesure et l'effort. Un cas d'usage n'est retenu que si sa faisabilité est démontrée sur les données du projet.

Cas d'usage	Valeur	Faisabilité	Effort	Rang
U1 Proposer la catégorie à la mise en ligne	forte	établie, partie 3.2	moyen	1
U2 S'abstenir sous un seuil et router en revue	forte	établie, partie 4.2	faible	2
U3 Signaler les articles dont l'étiquette contredit le modèle	moyenne	sous-produit de U1	faible	3
U4 Élargir la gamme par collecte externe	moyenne	établie mais dégradée, partie 3.5	moyen	4
U5 Classer sur la nomenclature complète	moyenne	non établie, volume insuffisant	fort	écarté
U6 Rechercher des articles visuellement similaires	faible	non mesurée	moyen	écarté

U1 à U3 partagent un même modèle : U2 et U3 se dérivent des probabilités produites par U1, sans coût supplémentaire.

3.2 Comparatif des approches

Mesures employées.


Question	Mesure	Pourquoi celle-ci
Les catégories existent-elles dans les données ?	indice de Rand ajusté entre groupes formés et catégories réelles	compare deux partitions sans supposer que les groupes portent les bons noms
À quoi ressemblent les données ?	ACP à 50 composantes puis t-SNE	rend visible en deux dimensions un espace à plusieurs milliers ; sert à voir, jamais à décider
Quelle représentation classe le mieux ?	F1 macro	moyenne à poids égal sur les 7 catégories : une catégorie faible n'est pas masquée
Où sont les erreurs ?	matrice de confusion et F1 par catégorie	une moyenne ne dit pas quelles catégories se confondent

L'information est-elle présente dans les données existantes ? Catégories masquées, huit représentations projetées, les sept imposées par le brief et une variante en bigrammes, partitionnement

en sept groupes, accord mesuré par l'indice de Rand ajusté (annexe B).

VGG16 **0,510** · USE 0,440 · TF-IDF 0,325 · BERT 0,316 · Word2Vec 0,300 · SIFT 0,044.

Projection. ACP à 50 composantes, puis t-SNE. Chaque article est préalablement ramené à une longueur unitaire, ce qui rend la distance euclidienne équivalente à la distance cosinus. Sur une projection t-SNE, seules les proximités entre points ont un sens, l'échelle des axes n'en a pas.



Un indice de 0,51 n'est pas une proportion d'articles bien classés, mais une mesure de correspondance entre deux partitions. Sur les mêmes photographies, un réseau convolutif atteint 0,510 quand SIFT reste au niveau du hasard : une méthode reconnue peut répondre à une autre question que celle posée. Côté texte, un comptage simple de mots fait jeu égal avec BERT, le vocabulaire discriminant et la syntaxe presque absente.

L'information nécessaire est présente dans les données déjà fournies par les vendeurs. U1 est faisable, l'image en étant la source la plus prometteuse en non supervisé. La confusion la plus tenace, des textiles imprimés photographiés à plat mêlant *Home Furnishing* et *Baby Care*, 69 articles déplacés, traverse ensuite tout le projet : l'algorithme regroupe par matière et mise en scène, la nomenclature par usage commercial.

Quelle représentation retenir en supervisé ? Découpe stratifiée figée des 1 050 articles en 735 entraînement, 157 validation, 158 test ; extracteurs pré-entraînés conservés figés ; une architecture de classifieur unique, un perceptron à une couche cachée de 256 neurones, entraîné indépendamment derrière chaque représentation. Un écart entre deux lignes ne peut donc provenir que de la représentation. Sélection au F1 macro sur la validation ; le jeu de test n'intervient jamais dans la sélection.

Représentation	Modalité	Dimensions	F1 macro, validation
TF-IDF	texte	4 532	0,937
DINOv2 figé, Vision Transformer	image	1 536	0,912
BERT figé	texte	768	0,905
ModernBERT figé	texte	768	0,904
VGG16 figé, CNN	image	512	0,822

Côté texte, les deux encodeurs figés ne devancent pas la référence lexicale. Côté image, DINOv2 dépasse VGG16 de neuf points, sur les mêmes photographies.

Les deux modalités se complètent-elles ? Les deux meilleures représentations par modalité sont concaténées après normalisation ligne à ligne, soit 6 068 caractéristiques, même classifieur : la fusion obtient **0,937** sur la validation, contre 0,937 pour TF-IDF seul. Les deux configurations sont indiscernables à cette précision, aucun gain de la multimodalité n'est établi sur ce corpus. La règle de sélection fixée d'avance désigne la fusion. La lecture par catégorie (annexe B) est plus informative que la moyenne : la fusion gagne sur *Kitchen & Dining* et *Beauty and Personal Care*, perd sur *Computers et Home Decor & Festive Needs*.

Approche	Avantage	Inconvénient
TF-IDF seul	performance de tête, coût négligeable, interprétable	muet sur un article mal décrit
Encodeur de texte figé	robuste aux reformulations	ne devance pas TF-IDF ici, coût supérieur
VGG16 figé	rapide, éprouvé	neuf points sous DINOv2
DINOv2 figé	meilleure représentation image, indépendante du texte	poste de calcul dominant
Fusion TF-IDF ⊕ DINOv2	retenue par la règle ; les modalités ne faiblissent pas aux mêmes endroits	coût de DINOv2 sans gain moyen établi

3.3 Classification supervisée à partir des images seules

Demande distincte du brief, même protocole. Extracteur VGG16 figé, tête de classification apprise, quatre stratégies d'augmentation comparées sur la validation (annexe B) : écart maximal de 0,006 point, insuffisant pour conclure à une amélioration nette. L'augmentation déplace les erreurs plutôt qu'elle ne les supprime. Configuration retenue selon la règle fixée d'avance, augmentation douce ×4, avantage non établi.


Évaluation finale, jeu de test, une seule ouverture : **137 / 158 articles correctement classés, exactitude 86,7 %, F1 macro 0,867**, sans aucun recours au texte.

Augmentation douce $\times 4$: 158 produits de test, ouverts une seule fois
F1 macro 0,867

Catégorie réelle	Baby Care	19	0	0	1	2	0	0
	Beauty & Personal Care	1	18	0	0	1	1	1
	Computers	0	0	17	3	0	3	0
	Home Decor & Festive Needs	1	0	0	21	0	1	0
	Home Furnishing	2	0	1	1	19	0	0
	Kitchen & Dining	0	0	0	1	0	21	0
	Watches	0	0	1	0	0	0	22
		Baby Care	Beauty & Personal Care	Computers	Home Decor & Festive Needs	Home Furnishing	Kitchen & Dining	Watches
		Catégorie prédite						

La confusion *Baby Care* et *Home Furnishing* reproduit celle de l'étude non supervisée : ambiguïté réelle entre certaines images, réduite par la supervision, non éliminée.

3.4 Architecture cible



Évaluation finale de la solution retenue. Jeu de test, une seule ouverture : **F1 macro 0,987, 156 / 158 articles correctement classés**. Les deux erreurs restantes : un lit king size étiqueté *Beauty and Personal Care*, lu *Home Furnishing*, étiquette probablement incohérente ; un sticker mural lu *Baby Care*, ambiguïté d'univers domestique déjà observée en partie 3.2.

Choix	Justification
Extracteurs figés, non réglés finement	735 images d'entraînement ; le réglage fin relève d'une expérimentation dédiée
Perceptron à une couche de 256	architecture constante entre les lignes comparées : c'est ce qui rend le comparatif interprétable
Fusion par concaténation, normalisation ligne à ligne	sans état à ajuster entre articles, donc sans fuite possible
Sérialisation en artefact unique de 37,5 Mo	transportable, chargeable sans base de modèles
Interface applicative conteneurisée	déploiement reproductible, indépendant de la machine hôte
Décision par seuil, séparée du modèle	paramètre métier révisable sans réentraînement
Journalisation et surveillance de dérive	proposées, sans objet avant une mise en service

Adéquation aux besoins.

Axe	Constat	Verdict
Fonctionnalités	U1 à U3 couverts par un modèle unique	conforme
Performances	F1 macro 0,987, 156 / 158 sur jeu réservé	conforme
Réglementaire	aucune donnée personnelle, champ brand écarté	à réexaminer avant extension
Sécurité	entrées libres à valider, interface à authentifier	disposition à mettre en place
Scalabilité	1,62 h de calcul pour 100 000 articles	conforme, traitement par lots
Coûts	extraction d'image à 99,8 % du coût d'inférence	levier identifié

Poste	Coût mesuré par article
Extraction DINOv2	58,09 ms
Vectorisation TF-IDF	0,10 ms
Tête de classification	0,02 ms
Total	58,22 ms

Renoncer à la modalité image ramènerait l'inférence à 0,12 ms par article, pour une F1 macro de validation inchangée à cette précision.

3.5 Collecte externe

Cas d'usage U4, éprouvé sur l'épicerie fine. Source retenue : Open Food Facts, sans inscription, donc rejouable par un tiers. Correspondances vers le schéma cible isolées dans un dictionnaire unique, filtrage par catégorie plutôt que par texte libre. Résultat : 10 produits collectés, cinq champs renseignés, composition manquante pour 2 produits.

Le contenu est hétérogène : 5 étiquettes de catégorie différentes pour 10 produits, des libellés non traduits (*fr:Champagnes bruts*), un quasi vide de sens (*fr:Liquide*), un libellé mêlant caractères cyrilliques et fragments d'étiquette, et un cocktail à la pêche parmi les « champagnes ». La faisabilité technique est établie, la qualité des métadonnées ne l'est pas : les catégories y sont, comme sur la place de marché, déclarées par des contributeurs sans règle commune.

4. Stratégie de mise en œuvre

4.1 Démarche projet

Découpage en lots courts, chacun sur sa propre branche, fusionné après revue, puis étiqueté. Les jalons sont les versions réellement publiées du dépôt.

Phase	Contenu	Outils	Jalon	État
1. Audit des données	profilage, contrôle de la cible, détection de fuite	pandas, matplotlib	v0.1.0	réalisé
2. Faisabilité	huit représentations, projection, partitionnement, accord	scikit-learn, PyTorch, TensorFlow Hub	v0.1.0	réalisé
3. Comparatif supervisé	protocole constant, cinq représentations, fusion	scikit-learn, transformers	v1.0.0	réalisé
4. Qualité et rejeu	tests unitaires, test anti-fuite, intégration continue	pytest, ruff, GitHub Actions	v1.0.1	réalisé
5. Démonstrateur	interface de démonstration, trois modalités comparées	Streamlit, Docker	v1.1.0	réalisé
6. Documentation	rapport, carnets exécutés, README	Markdown, nbformat	v2.0.0	réalisé
7. Mise en service	interface authentifiée, seuil paramétrable	FastAPI, Docker	à planifier	proposé
8. Surveillance	journalisation, suivi du taux d'automatisation, dérive	journaux applicatifs	à planifier	proposé
9. Réentraînement	corpus ré-étiqueté, rejeu du protocole	chaîne existante, inchangée	à planifier	proposé

Les phases 1 à 6 ont été conduites par une seule personne, de la conception à la rédaction. Les phases 7 à 9 supposent une intégration dans le système de la place de marché et une équipe pour la revue des cas incertains.

4.2 Aide à la prise de décision

Indicateurs, définis puis évalués. Le seuil de décision est choisi sur la validation, selon une exigence posée d'avance : au moins 99 % de propositions correctes sur la part automatisée. Le seuil le plus bas qui la satisfait est 0,60. Le couple d'indicateurs est ensuite mesuré une seule fois sur le jeu de test.

Indicateur	Nature	Cible	Validation	Test
Taux d'automatisation	business	maximiser	84,1 %	85,4 %
Propositions correctes sur la part automatisée	business	≥ 99 %	0,992	0,993
Volume en revue humaine	business	minimiser	25 / 157	23 / 158
F1 macro	technique	≥ 0,90	0,937	0,987
Latence d'inférence	technique	compatible interactif	non applicable	58,22 ms
Rejeu complet de la chaîne	technique	une commande	vérifié en intégration continue	vérifié

Une seule erreur subsiste dans la part automatisée du jeu de test, sur 135 articles traités sans intervention. Le seuil transforme un modèle à deux erreurs en un service dont l'erreur résiduelle automatisée est unitaire, au prix de 14,6 % du volume envoyé en revue.

Risques et mesures.

Risque	Impact	Mesure
Étiquettes vendeurs bruitées	performance biaisée, plafond de mesure	revue d'un échantillon par l'équipe catalogue, en priorité les contradictions confiantes (U3)
Distribution artificielle, 7 × 150	généralisation inconnue	réévaluation sur un extrait réel du catalogue
Photographies de catalogue soignées	baisse probable en production	mesure sur un lot de prises de vue vendeurs
Coût de DINOv2	latence et coût d'exploitation	traitement par lots, cache, ou repli sur le texte seul
Dérive du catalogue	perte de justesse silencieuse	suivi du taux d'automatisation, seuil d'alerte
Entrées vendeurs non maîtrisées	sécurité	validation des formats et des tailles en entrée
Charge de revue non affectée	14,6 % du volume sans destinataire	dimensionner la file avant ouverture du service
Images sous licence de recherche	réutilisation en production exclue	constituer un corpus propre à l'entreprise

Deux propriétés jouent en sens inverse : le seuil est un paramètre métier, donc l'arbitrage automatisation contre justesse se révisé sans réentraînement ; et la modalité image est séparable, ce qui ouvre deux niveaux de service, économique ou complet.

Scénarios. Les charges n'ont pas été estimées dans le cadre du projet.

Scénario	Périmètre	Charge
Démonstrateur	état actuel	réalisé
Mise en service	interface authentifiée, seuil paramétrable, journalisation	à estimer
Industrialisation	surveillance, réentraînement, interface de revue	à estimer

5. Contrôle et suivi du projet

5.1 Tableau de bord

Indicateur	Source	Valeur de fin de projet
Avancement	jalons publiés du dépôt	6 phases sur 6 du périmètre, 7 versions étiquetées
Délais	historique du dépôt	4 lots livrés, chacun sur sa branche puis fusionné
Livrables	dépôt et documentation	3 scripts d'exécution, 6 carnets exécutés, rapport, démonstrateur en ligne
Qualité des données	profilage et contrôles	1 fuite détectée et neutralisée, 2 anomalies de format corrigées
Qualité logicielle	intégration continue	23 tests, dont un test anti-fuite ; lint et format à chaque poussée
Performances	jeu réservé, une ouverture	F1 macro 0,987, 156 / 158
Coût de calcul	mesure locale	chaîne complète rejouée en environ 20 minutes

Gestion. Flux à trois niveaux : `main` porte les versions publiées, `develop` intègre, chaque lot vit sur sa propre branche avant fusion. Versions sémantiques étiquetées à chaque livraison, intégration continue déclenchée sur les trois niveaux. Un correctif urgent a suivi le chemin dédié (`hotfix/`), après détection d'un défaut de collecte des tests depuis un clone vierge.

5.2 Tests et suivi

Niveau	Objet	Dispositif
Unitaire	découpe, métriques, fusion, vectorisation	23 tests, exécutés à chaque poussée
Intégrité du protocole	les trois parts sont disjointes	test dédié, échoue si une fuite apparaît
Reproductibilité	la chaîne se rejoue depuis un clone vierge	tâche d'intégration continue distincte
Non-régression	le modèle rechargé reproduit le résultat publié	vérification à la sérialisation, artefact supprimé si écart
Bout en bout	interface sur articles jamais vus	démonstrateur conteneurisé, en ligne

Deux erreurs de méthode corrigées en cours de projet, aucune n'ayant été signalée par un test en échec : le code fonctionnait, il mesurait autre chose que ce qui était visé.

Erreur	Correction	Conséquence
Comparaison des stratégies d'augmentation lue sur le jeu de test	sélection reportée sur la validation	configuration retenue modifiée
Standardisation par dimension avant projection, accord TF-IDF tombé à 0,001	normalisation ligne à ligne	accord rétabli à 0,325

Le jeu de test a donc été consulté avant la correction du protocole. Le résultat final procède, lui, d'une sélection faite sur la validation. Chaque chiffre du rapport est pour cette raison accompagné de son protocole.

Suivi en production, proposé : taux de refus des propositions par les vendeurs, part du volume au-dessus du seuil, distribution des confiances maximales pour la dérive des entrées, volume et délai d'écoulement de la file de revue, latence et taux d'erreur de l'interface.

6. Conclusion et recommandations

L'information nécessaire à la catégorisation est présente dans les données déjà fournies par les vendeurs : la faisabilité est établie avant tout engagement. Le comparatif à protocole constant désigne la fusion TF-IDF $\oplus$ DINOv2, qui obtient 0,987 de F1 macro et 156 articles sur 158 sur un jeu réservé ouvert une seule fois. La décision est séparée du modèle par un seuil de confiance choisi sur la validation, qui automatise 85,4 % du volume avec 0,993 de propositions correctes. Les modèles récents n'apportent

pas systématiquement un gain : net en vision, nul ici sur le texte figé, où une référence lexicale reste en tête.

Recommandations, par ordre de priorité. La première est la prochaine étape.

1. Faire arbitrer par l'équipe catalogue les frontières ambiguës, et ré-étiqueter en priorité les articles où le modèle contredit le vendeur avec une confiance élevée.
2. Mettre en service l'interface authentifiée avec seuil paramétrable et journalisation des prédictions.
3. Dimensionner la file de revue humaine avant l'ouverture du service, 14,6 % du volume étant concerné.
4. Réévaluer la performance sur un extrait réel du catalogue, à distribution non équilibrée et photographies non retouchées.
5. Constituer un corpus propre à l'entreprise, les images d'étude étant sous licence de recherche.
6. Traiter la qualité des métadonnées externes avant d'envisager l'élargissement de gamme.

Perspectives. Réglage fin des extracteurs sur corpus élargi ; classification sur la nomenclature complète ; augmentation différenciée par type de produit ; recherche d'articles visuellement similaires, qui réutiliserait les représentations déjà calculées.

Annexes

A. Rejeu de l'étude

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements-encoders.txt

python faisabilite.py                # les huit représentations, projections, partition
python supervise_image.py            # classification supervisée et augmentation
python collecte_api.py               # collecte « champagne » et fichier CSV
python scripts/comparer_modernes.py  # le comparatif des représentations et la fusion
python scripts/seuil_confiance.py    # seuil de décision et indicateurs d'automatisation
python scripts/cout_inference.py     # coût d'inférence, poste par poste
python scripts/rapport_classification.py # précision et rappel par catégorie
python scripts/schemas.py           # les deux schémas de flux et d'architecture
```

Le socle seul (`requirements.txt`) suffit pour l'exploration des données et les modèles classiques ; `requirements-encoders.txt` ajoute les réseaux pré-entraînés, soit environ 3 Go de poids au premier lancement. Les versions sont épinglées, la graine aléatoire est fixe, et la découpe des données est définie dans un module unique (`src/pipeline.py`) appelé par tous les scripts. Les caractéristiques extraites sont mises en cache : une seconde exécution ne recalcule ni SIFT ni les réseaux.

B. Tableaux détaillés

Précision, rappel et F1 par catégorie. Modèle retenu, jeu réservé, unique ouverture. Détail de la même évaluation que la partie 3.4, non une seconde mesure.

Catégorie	Précision	Rappel	F1	Articles
Baby Care	0,957	1,000	0,978	22
Beauty and Personal Care	1,000	0,955	0,977	22
Computers	1,000	1,000	1,000	23
Home Decor & Festive Needs	1,000	0,957	0,978	23
Home Furnishing	0,958	1,000	0,979	23
Kitchen & Dining	1,000	1,000	1,000	22
Watches	1,000	1,000	1,000	23
Moyenne macro	0,988	0,987	0,987	158

Les deux erreurs se lisent en creux : un article de *Beauty and Personal Care* manqué, d'où un rappel de 0,955 sur cette catégorie et une précision de 0,958 sur *Home Furnishing* qui l'a absorbé ; un article de *Home Decor & Festive Needs* manqué, absorbé par *Baby Care*.

Accord entre groupes non supervisés et catégories réelles. Mesure rapportée deux fois, avant et après réduction, la réduction étant déformante.

Représentation	Modalité	Dimensions	Accord, projection	Accord, espace complet
CNN (VGG16)	image	512	0,510	0,540
USE	texte	512	0,440	0,333
TF-IDF	texte	5 000	0,325	0,214
Comptage + bigrammes	texte	5 000	0,316	0,227
BERT	texte	768	0,316	0,288
Comptage de mots	texte	2 444	0,306	0,270
Word2Vec	texte	300	0,300	0,207
SIFT + BoVW	image	256	0,044	0,056

Correspondance de un à un entre groupes et catégories pour VGG16 : informatique 87 %, montres 86 %, beauté 80 %. VGG16 est la seule représentation meilleure avant réduction qu'après, la séparation existant déjà dans l'espace d'origine.

Stratégies d'augmentation, sur la validation.

Stratégie	Images d'entraînement	F1 macro
Augmentation douce ×4	3 675	0,828
Augmentation forte ×4	3 675	0,827
Sans augmentation	735	0,822
Augmentation forte ×8	6 615	0,815

C. Figures et fichiers produits

Fichier	Contenu
reports/fig3_transformations.png	La chaîne de transformation du texte, sur un article réel
reports/fig4_donnees.png	Équilibre des classes et distribution des longueurs
reports/fig5_projections.png	Les huit projections en deux dimensions
reports/fig6_clusters.png	VGG16 : catégories réelles et groupes trouvés
reports/fig7_ari.png	L'accord entre groupes et catégories, par représentation
reports/fig8_confusion_image.png	Matrice de confusion du modèle supervisé image
reports/fig9_augmentation_par_classe.png	L'effet de l'augmentation, catégorie par catégorie
reports/fig10_comparaison_par_classe.png	F1 par catégorie des six configurations comparées
reports/fig11_flux_actuel.png	Le processus de catégorisation en place
reports/fig12_architecture_cible.png	L'architecture cible et son socle technique
reports/faisabilite.csv	Dimensions et accords des huit représentations
reports/supervise_image_validation.csv	Comparaison des stratégies d'augmentation
reports/comparaison_validation.csv	Le comparatif des représentations, sur la validation
reports/comparaison_test.csv	L'évaluation finale de la fusion, sur le jeu réservé
reports/classification_test.csv	Précision, rappel et F1 par catégorie, modèle retenu
reports/seuil_confiance.csv	Automatisation et justesse par seuil, validation et test
reports/cout_inference.json	Coût d'inférence par poste et par volume
reports/produits_champagne.csv	Les dix produits collectés via l'interface externe

D. Ressources du projet

Ressource	Adresse
Dépôt du projet	https://github.com/richardhugou/product-category-classifier
Démonstrateur en ligne	https://huggingface.co/spaces/trikwi/projet55
Portfolio	https://portfolio.richardh.fr
Description du dépôt	README.md
Carnets exécutés, dans l'ordre de la mission	notebooks/

E. Notes techniques

Universal Sentence Encoder et la cohabitation TensorFlow et PyTorch. USE est distribué pour TensorFlow, quand le reste de la chaîne repose sur PyTorch. Chargées dans un même processus, les deux bibliothèques se sont bloquées mutuellement sans lever d'erreur ; isolé dans son propre processus, le modèle se charge en deux secondes. L'encodage USE est donc délégué à un sous-processus dédié. Par ailleurs, `tensorflow_hub` importe encore `pkg_resources`, retiré de `setuptools` à partir de la version 81 : la borne haute des dépendances est là pour cette seule raison.

Point d'entrée de l'interface Open Food Facts. L'ancien point d'entrée `cgi/search.pl`, déprécié, a renvoyé une erreur de service lors du premier essai. Le script utilise le point d'entrée `v2`, maintenu, et réessaie avec une attente croissante.

Mesure du coût d'inférence. Latences mesurées sur poste local, accélérateur intégré, sur un échantillon de 16 photographies pour l'extraction et sur les 158 articles du jeu réservé pour le texte et la tête de classification. Un passage à blanc précède la mesure pour ne pas compter l'allocation initiale.