

Automatisation de la catégorisation d'articles sur une place de marché

Rapport de conduite de projet AI Engineering

Richard Hugou · Data Scientist & AI Engineer
août 2026

Projet technique : github.com/richardhugou/product-category-classifier

Portfolio : portfolio.richardh.fr

1. Contexte et analyse des besoins

1.1 Contexte de l'organisation

Élément	État constaté
Activité	place de marché généraliste anglophone, mise en relation vendeurs et acheteurs
Modèle de mise en ligne	dépôt libre par le vendeur : une photographie, une description, une catégorie déclarée
Volume	catalogue en phase de croissance ; échantillon de travail de 1 050 articles sur 7 catégories
Maturité IA et MLOps	nulle. Aucun modèle en service, aucune chaîne de données outillée, aucun indicateur de qualité du catalogue
Moyens de calcul	poste de travail local, sans accélérateur dédié ni budget d'infrastructure ouvert

Enjeux exprimés par le commanditaire : fluidifier la mise en ligne côté vendeur, fiabiliser le filtrage par catégorie côté acheteur. Le second dépend du premier : un article mal rangé n'est pas retrouvé par l'acheteur qui filtre, et le vendeur n'en est jamais informé.

Le moment est déterminé par la trajectoire du catalogue, non par un incident : l'automatisation doit être disponible avant que le volume rende la correction manuelle impraticable.

Contraintes de départ.

- Techniques : calcul local, absence d'accélérateur, artefacts devant rester transportables.
- Sécurité : aucune donnée personnelle dans le périmètre ; descriptions et photographies fournies par les vendeurs, donc entrées non maîtrisées.
- Scalabilité : la solution doit tenir sur un catalogue d'un ordre de grandeur supérieur à l'échantillon.
- Déploiement : aucune plateforme d'hébergement de modèle en place à la date du projet.

1.2 Recueil et analyse du besoin métier

Parties prenantes.

Partie prenante	Rôle dans le projet	Attente principale
Lead Data Scientist	commanditaire, cadrage et arbitrage technique	faisabilité établie avant tout engagement
Équipe catalogue	propriétaire de la nomenclature, arbitre des frontières ambiguës	règles de classement explicites et stables
Vendeurs	producteurs de la donnée d'entrée et de l'étiquette actuelle	mise en ligne plus rapide, sans saisie contrainte
Acheteurs	consommateurs du filtrage	catégories fiables
Équipe plateforme	intégration et exploitation	interface simple, coût d'exploitation prévisible

Méthode de recueil. Le besoin a été recueilli par deux voies, sans atelier collectif :

1. **Brief écrit du commanditaire**, en deux demandes successives : établir la faisabilité à partir des données existantes, puis produire une classification supervisée à partir des images. Une troisième demande, distincte, porte sur la collecte de nouveaux produits via une interface externe.
2. **Analyse documentaire du jeu de données**, outillée : profilage des champs, des longueurs de description, des formats d'image, du taux de complétude (`scripts/profile_data.py`). Cette analyse a fait remonter deux besoins non exprimés dans le brief, la neutralisation du champ `brand` et l'harmonisation des formats d'image.

La reformulation du besoin a été soumise au commanditaire avant tout développement, sous la forme du périmètre repris en 1.2 ci-dessous.

Objectifs.

Nature	Objectif	Traduction mesurable
Business	réduire le temps de mise en ligne	part du catalogue classée sans intervention humaine
Business	réduire les articles mal rangés	taux de propositions correctes sur la part automatisée
Technique	établir que la catégorie est déductible des données existantes	accord entre groupes non supervisés et catégories réelles
Technique	disposer d'un modèle évalué sur données jamais vues	F1 macro et exactitude sur un jeu réservé
Technique	garantir la reproductibilité de la chaîne	rejeu complet en une commande, depuis un dépôt vierge

Contraintes fonctionnelles, non fonctionnelles et réglementaires.

Type	Contrainte	Conséquence retenue
Fonctionnelle	premier niveau de nomenclature uniquement, 7 catégories	granularité fine hors périmètre
Fonctionnelle	proposition, jamais imposition, de la catégorie au vendeur	sortie probabiliste, décision séparée du modèle
Non fonctionnelle	latence compatible avec une mise en ligne interactive	mesure du coût d'inférence par article
Non fonctionnelle	reproductibilité et traçabilité des essais	découpe unique, graine fixe, versions épinglées
Organisationnelle	aucune équipe d'annotation disponible	pas de ré-étiquetage massif du corpus
Réglementaire	corpus sans donnée personnelle, images sous licence de recherche	usage d'étude ; toute extension à des données vendeurs relève du RGPD
Éthique	l'étiquette de référence est produite par les vendeurs	la performance mesurée est bornée par la qualité de cette référence

Hiérarchisation des besoins. Chaque besoin est coté sur son impact métier et sur l'effort de réalisation, puis positionné. La cotation est celle du commanditaire pour l'impact, celle du projet pour l'effort.


Besoin	Impact	Effort	Décision
Établir la faisabilité avant tout engagement	fort	faible	retenu, priorité 1
Classer automatiquement à partir du texte et de l'image	fort	moyen	retenu, priorité 2
Décider quand ne pas trancher, et router en revue humaine	fort	faible	retenu, priorité 3
Neutraliser les champs porteurs de fuite (brand)	moyen	faible	retenu, priorité 4
Éprouver la collecte externe pour un élargissement de gamme	moyen	moyen	retenu, priorité 5
Classification hiérarchique complète	moyen	fort	écarté de ce périmètre
Réglage fin des extracteurs pré-entraînés	faible	fort	écarté, volume insuffisant
Interface de correction pour l'équipe catalogue	faible	moyen	reporté après mise en service

Les cinq premiers besoins constituent le périmètre du projet. Les trois derniers sont documentés comme perspectives en partie 6.

2. Audit de la solution existante

2.1 Processus en place

Aucune brique logicielle n'intervient aujourd'hui entre le vendeur et le catalogue. La catégorie est saisie dans un formulaire libre, enregistrée telle quelle, puis utilisée comme clé de filtrage.



Composant	Nature	Outillage
Saisie	formulaire de mise en ligne	champ de nomenclature déclaratif
Stockage	catalogue produits	arborescence de catégories sur plusieurs niveaux
Restitution	recherche et filtres	filtrage exact sur le premier niveau
Contrôle qualité	aucun	ni règle partagée, ni revue, ni indicateur

Données disponibles par article : `product_name`, `description` rédigée par le vendeur, `product_category_tree`, une photographie, et une quinzaine de champs annexes hors périmètre.

Exemple de référence, conservé dans tout le rapport.

Champ	Contenu
<code>product_name</code>	V9 METAL STRAP Analog Watch – For Men
<code>description</code>	<i>Specifications of V9 METAL STRAP Analog Watch – For Men. General Type Analog. Style Code METAL STRAP. Occasion Casual. Ideal For Men. Warranty NO. Body Features Dial Shape Round. Strap Color STEEL. Dial Color BLACK.</i>
<code>product_category_tree</code>	<code>["Watches >> Wrist Watches >> V9 Wrist Watches >> ..."]</code>
<code>image</code>	photographie de 1 152 × 1 816 pixels


2.2 Démarche d'audit et adéquation aux besoins

Démarche. Trois étapes, outillées et rejouables : profilage descriptif de chaque champ, contrôle de la cible, contrôle des entrées. Référentiel appliqué : complétude, validité, cohérence, représentativité, absence de fuite. L'audit porte sur les données et sur le processus, aucun composant logiciel n'étant en place.

Cible. La catégorie n'est pas un champ, mais le premier niveau d'une chaîne d'arborescence mal formée, aux échappements incohérents. Son extraction produit les sept catégories du périmètre : *Baby Care*, *Beauty and Personal Care*, *Computers*, *Home Decor & Festive Needs*, *Home Furnishing*, *Kitchen & Dining*, *Watches*. Elle est déclarée par les vendeurs : la référence d'évaluation est elle-même faillible.

Entrées.

- Descriptions : formulaires de spécifications aplatis, non des textes rédigés. 13 à 587 mots, médiane 44. Longueur médiane variable selon la catégorie, de 24 mots pour *Home Furnishing* à 88 pour *Kitchen & Dining*.
- Photographies : 890 tailles distinctes sur 1 050 fichiers, ratios de 0,23 à 4,36, jusqu'à 93 mégapixels. Harmonisation obligatoire avant tout traitement.



Fuite détectée. Le champ `brand` présente 32 % de valeurs manquantes, et cette absence est fortement corrélée à la catégorie : 95 % des 338 absences se concentrent sur trois catégories.

Catégorie	Marque absente
Watches	140 / 150
Beauty and Personal Care	109 / 150
Kitchen & Dining	71 / 150
Baby Care	16 / 150
Home Decor & Festive Needs	2 / 150
Computers	0 / 150
Home Furnishing	0 / 150

Un modèle recevant ce champ apprendrait une habitude de saisie, non le produit. Exclusion décidée, indicateur d'absence compris.

Adéquation du processus actuel aux besoins.

Axe	Constat	Écart au besoin
Fonctionnalités	la catégorie est renseignée pour tout article	aucune garantie qu'elle soit juste
Performances	saisie instantanée	aucune mesure de justesse, donc aucun pilotage possible
Réglementaire	pas de donnée personnelle traitée	conforme, aucun écart
Sécurité	entrées libres non validées	texte et image non contrôlés en entrée de chaîne
Scalabilité	coût de saisie linéaire au volume	la correction manuelle devient impraticable à l'échelle
Coûts	aucun coût logiciel	coût caché : invendus liés aux articles introuvables

Deux écarts commandent la suite : l'absence de toute mesure de qualité, et l'absence de règle commune entre vendeurs. Aucun ne se corrige par un ajustement du formulaire.

3. Solution technique cible

3.1 Identification, évaluation et hiérarchisation des cas d'usage

Méthode. Les cas d'usage sont dérivés des besoins hiérarchisés en 1.2, puis cotés sur trois critères : valeur métier attendue, faisabilité établie par la mesure, effort de mise en œuvre. Un cas d'usage n'est retenu que si sa faisabilité est démontrée sur les données du projet, non supposée.

Cas d'usage	Valeur	Faisabilité	Effort	Rang
U1 Proposer la catégorie à la mise en ligne	forte	établie, partie 3.2	moyen	1
U2 S'abstenir sous un seuil de confiance et router en revue	forte	établie, partie 4.2	faible	2
U3 Signaler les articles dont l'étiquette contredit le modèle avec confiance	moyenne	établie, sous-produit de U1	faible	3
U4 Élargir la gamme par collecte externe	moyenne	établie mais dégradée, partie 3.5	moyen	4
U5 Classer sur la nomenclature complète	moyenne	non établie, volume insuffisant	fort	écarté
U6 Rechercher des articles visuellement similaires	faible	plausible, non mesurée	moyen	écarté


U1 à U3 forment le service cible et partagent un même modèle : U2 et U3 se dérivent des probabilités produites par U1, sans coût supplémentaire. U4 est traité comme une étude distincte.

3.2 Comparatif des approches

Première question : l'information est-elle présente dans les données existantes ? Les catégories sont masquées, huit représentations du texte et de l'image sont projetées, les sept imposées par le brief et une variante en bigrammes, un partitionnement en sept groupes est calculé, puis l'accord avec les catégories réelles est mesuré par l'indice de Rand ajusté. Cette étape est descriptive et porte sur tout le corpus ; aucune décision de modèle n'en découle.


Représentation	Modalité	Dimensions	Accord, projection	Accord, espace complet
CNN (VGG16)	image	512	0,510	0,540
USE	texte	512	0,440	0,333
TF-IDF	texte	5 000	0,325	0,214
Comptage + bigrammes	texte	5 000	0,316	0,227
BERT	texte	768	0,316	0,288
Comptage de mots	texte	2 444	0,306	0,270
Word2Vec	texte	300	0,300	0,207
SIFT + BoVW	image	256	0,044	0,056

Règle de lecture : un indice de 0,51 n'est pas une proportion d'articles bien classés, mais une mesure de correspondance entre deux partitions. La mesure est rapportée deux fois, avant et après réduction, la réduction étant déformante.



Constats :

- Sur les mêmes photographies, un réseau convolutif atteint 0,510 quand SIFT reste au niveau du hasard. Une méthode reconnue peut répondre à une autre question que celle posée.
- VGG16 est la seule représentation meilleure avant réduction qu'après : la séparation existe dans l'espace d'origine.
- Côté texte, un comptage simple de mots fait jeu égal avec BERT. Sur des fiches de spécifications, le vocabulaire discrimine et la syntaxe est presque absente.




Correspondance de un à un entre groupes et catégories pour VGG16 (informatique 87 %, montres 86 %, beauté 80 %). Deux zones de confusion : un groupe de textiles imprimés photographiés à plat mêle *Home Furnishing* et *Baby Care*, 69 articles déplacés ; 31 objets décoratifs de *Home Decor* partent vers l'ameublement. L'algorithme regroupe par matière et mise en scène, la nomenclature par usage commercial.

Conclusion de l'étape : l'information nécessaire est présente dans les données déjà fournies par les vendeurs. Le cas d'usage U1 est faisable. L'image en est la source la plus prometteuse en non supervisé.

Deuxième question : quelle représentation retenir en supervisé ? Protocole commun à toutes les lignes qui suivent : découpe stratifiée figée des 1 050 articles en 735 entraînement, 157 validation, 158 test ; extracteurs pré-entraînés conservés figés ; une architecture de classifieur unique, un perceptron à une couche cachée de 256 neurones, entraîné indépendamment derrière chaque représentation. Un écart entre deux lignes ne peut donc provenir que de la représentation. Sélection au F1 macro sur la validation ; le jeu de test n'intervient jamais dans la sélection.

Représentation	Modalité	Dimensions	F1 macro, validation
TF-IDF	texte	4 532	0,937
DINOv2 figé, Vision Transformer	image	1 536	0,912
BERT figé	texte	768	0,905
ModernBERT figé	texte	768	0,904
VGG16 figé, CNN	image	512	0,822

- Texte : ModernBERT et BERT sont séparés de 0,001 dans ce régime figé, et la référence lexicale TF-IDF les devance tous deux.
- Image : DINOv2 dépasse VGG16 de neuf points, sur les mêmes photographies et dans les mêmes conditions.
- Le VGG16 de ce tableau reproduit exactement le résultat sans augmentation de la partie 3.3 : les deux volets se recoupent.



Troisième question : les deux modalités se complètent-elles ? Les deux meilleures représentations par modalité sont concaténées après normalisation ligne à ligne, soit 6 068 caractéristiques, avec la même architecture de classifieur.

Configuration	F1 macro, validation
Fusion TF-IDF ⊕ DINOv2	0,937
TF-IDF seul	0,937

Les deux configurations sont indiscernables à cette précision : aucun gain de la multimodalité n'est établi sur ce corpus. La règle de sélection fixée d'avance, meilleur F1 macro de validation, désigne la fusion. La lecture par catégorie est plus informative que la moyenne : la fusion gagne sur *Kitchen & Dining* et *Beauty and Personal Care*, perd sur *Computers* et *Home Decor & Festive Needs*.

Avantages et inconvénients des approches candidates.


Approche	Avantage	Inconvénient
TF-IDF seul	performance de tête, coût négligeable, artefact léger, interprétable terme à terme	dépend du vocabulaire ; muet sur un article mal décrit
Encodeur de texte figé	robuste aux reformulations	ne devance pas TF-IDF ici ; coût d'inférence supérieur
VGG16 figé	rapide, largement éprouvé	neuf points en dessous de DINOv2
DINOv2 figé	meilleure représentation image, indépendante du texte	poste de calcul dominant
Fusion TF-IDF ⊕ DINOv2	retenue par la règle de sélection ; les deux modalités ne faiblissent pas aux mêmes endroits	coût de DINOv2 sans gain moyen établi

3.3 Classification supervisée à partir des images seules

Demande distincte du commanditaire, traitée avec le même protocole. Extracteur VGG16 figé, tête de classification apprise, quatre stratégies d'augmentation comparées sur la validation.

Stratégie	Images d'entraînement	F1 macro, validation
Augmentation douce ×4	3 675	0,828
Augmentation forte ×4	3 675	0,827
Sans augmentation	735	0,822
Augmentation forte ×8	6 615	0,815

Écart maximal de 0,006 point : insuffisant, sur cet échantillon de validation, pour conclure à une amélioration nette. La lecture par catégorie montre que l'augmentation déplace les erreurs plutôt qu'elle ne les supprime. Configuration retenue selon la règle fixée d'avance, augmentation douce ×4, avantage non établi.




Évaluation finale, jeu de test, une seule ouverture : **137 / 158 articles correctement classés, exactitude 86,7 %, F1 macro 0,867**, sans aucun recours au texte.

Augmentation douce $\times 4$: 158 produits de test, ouverts une seule fois
F1 macro 0,867

Catégorie réelle	Baby Care	19	0	0	1	2	0	0
	Beauty & Personal Care	1	18	0	0	1	1	1
	Computers	0	0	17	3	0	3	0
	Home Decor & Festive Needs	1	0	0	21	0	1	0
	Home Furnishing	2	0	1	1	19	0	0
	Kitchen & Dining	0	0	0	1	0	21	0
	Watches	0	0	1	0	0	0	22
		Baby Care	Beauty & Personal Care	Computers	Home Decor & Festive Needs	Home Furnishing	Kitchen & Dining	Watches
		Catégorie prédite						

La confusion *Baby Care* et *Home Furnishing* reproduit celle de l'étude non supervisée : ambiguïté réelle entre certaines images, réduite par la supervision, non éliminée.

3.4 Architecture cible



Évaluation finale de la solution retenue. Jeu de test, une seule ouverture : **F1 macro 0,987, 156 / 158 articles correctement classés.**

Les deux erreurs restantes : un lit king size étiqueté *Beauty and Personal Care*, lu *Home Furnishing*, étiquette probablement incohérente ; un sticker mural lu *Baby Care*, ambiguïté d'univers domestique déjà observée en partie 3.2.

Justification des choix techniques.

Choix	Justification
Extracteurs figés, non réglés finement	735 images d'entraînement ; le réglage fin relève d'une expérimentation dédiée et isolerait mal la qualité des représentations
Perceptron à une couche de 256	architecture constante entre toutes les lignes comparées : c'est ce qui rend le comparatif interprétable
Fusion par concaténation, normalisation ligne à ligne	sans état à ajuster entre articles, donc sans fuite possible du jeu de test
Sérialisation en artefact unique de 37,5 Mo	transportable, chargeable sans dépôt ni base de modèles
Interface applicative conteneurisée	déploiement reproductible, indépendant de la machine hôte
Décision par seuil, séparée du modèle	le seuil est un paramètre métier révisable sans réentraînement
Journalisation et surveillance de dérive	proposées, non réalisées : elles n'ont pas d'objet avant une mise en service

Adéquation de la cible aux besoins, six axes.

Axe	Mesure ou disposition	Verdict
Fonctionnalités	U1, U2 et U3 couverts par un modèle unique	conforme au périmètre
Performances	F1 macro 0,987 et 156 / 158 sur jeu réservé	conforme
Réglementaire	aucune donnée personnelle ; champ brand écarté ; images sous licence de recherche	conforme en l'état, à réexaminer avant extension
Sécurité	artefact sans secret ; entrées libres à valider ; interface à authentifier	disposition à mettre en place
Scalabilité	58,22 ms par article, soit 1,62 h de calcul pour 100 000 articles	conforme, traitement par lots possible
Coûts	extraction d'image à 99,8 % du coût d'inférence	conforme, avec un levier identifié

Le coût est concentré sur un seul poste, ce qui en fait le levier d'optimisation évident : renoncer à la modalité image ramènerait l'inférence à 0,12 ms par article, pour une F1 macro de validation inchangée à cette précision.

Poste	Coût mesuré par article
Extraction DINOv2	58,09 ms
Vectorisation TF-IDF	0,10 ms
Tête de classification	0,02 ms
Total	58,22 ms

3.5 Collecte externe pour un élargissement de gamme

Cas d'usage U4, éprouvé sur l'épicerie fine. Source retenue : Open Food Facts, sans inscription, donc rejouable par un tiers. Correspondances vers le schéma cible isolées dans un dictionnaire unique. Filtrage par catégorie plutôt que par texte libre.

Résultat : 10 produits collectés, cinq champs renseignés, composition manquante pour 2 produits.

Constats sur le contenu :

- 5 étiquettes de catégorie différentes pour 10 produits, dont des libellés non traduits (*fr:Champagnes bruts*) et un quasi vide de sens (*fr:Liquide*) ;
- un libellé mêlant caractères cyrilliques et fragments d'étiquette, signe d'une saisie collaborative non contrôlée ;
- un cocktail à la pêche parmi les « champagnes ».

La faisabilité technique est établie, la qualité des métadonnées ne l'est pas. Les catégories y sont, comme sur la place de marché, déclarées par des contributeurs sans règle commune : le même problème qu'en partie 2, sur une source que le projet ne maîtrise pas.

4. Stratégie de mise en œuvre et d'industrialisation

4.1 Démarche projet

Découpage en lots courts, chacun sur sa propre branche, fusionné après revue, puis étiqueté. Les jalons ci-dessous sont les versions réellement publiées du dépôt.

Phase	Contenu	Outils	Jalon	État
1. Audit des données	profilage, contrôle de la cible, détection de fuite	pandas, matplotlib	v0.1.0	réalisé
2. Faisabilité	huit représentations, projection, partitionnement, accord	scikit-learn, PyTorch, TensorFlow Hub	v0.1.0	réalisé
3. Comparatif supervisé	protocole constant, cinq représentations, fusion	scikit-learn, transformers	v1.0.0	réalisé
4. Qualité et rejeu	tests unitaires, test anti-fuite, intégration continue	pytest, ruff, GitHub Actions	v1.0.1	réalisé
5. Démonstrateur	interface de démonstration, trois modalités comparées	Streamlit, Docker	v1.1.0 , v1.1.1	réalisé
6. Documentation	rapport, carnets exécutés, README	Markdown, nbformat	v2.0.0 , v2.1.0	réalisé
7. Mise en service	interface applicative authentifiée, seuil de décision paramétrable	FastAPI, Docker	à planifier	proposé
8. Surveillance	journalisation des prédictions, suivi du taux d'automatisation, détection de dérive	journaux applicatifs, tableau de bord	à planifier	proposé
9. Réentraînement	corpus ré-étiqueté par l'équipe catalogue, rejeu du protocole	chaîne existante, inchangée	à planifier	proposé

Responsabilités. Sur les phases 1 à 6, conception, réalisation et rédaction assurées par l'auteur ; arbitrage du périmètre et validation des livrables par le commanditaire. Sur les phases 7 à 9, l'intégration relève de l'équipe plateforme, la revue des cas incertains et l'arbitrage des frontières de nomenclature relèvent de l'équipe catalogue.

4.2 Aide à la prise de décision

Indicateurs de succès, définis puis évalués. Le seuil de décision est choisi sur la validation, selon une exigence posée d'avance : au moins 99 % de propositions correctes sur la part automatisée. Le seuil le plus bas qui la satisfait est 0,60. Le couple d'indicateurs est ensuite mesuré une seule fois sur le jeu de test.

Indicateur	Nature	Cible	Mesuré sur validation	Mesuré sur test
Taux d'automatisation	business	maximiser	84,1 %	85,4 %
Propositions correctes sur la part automatisée	business	≥ 99 %	0,992	0,993
Volume en revue humaine	business	minimiser	25 articles sur 157	23 articles sur 158
F1 macro	technique	≥ 0,90	0,937	0,987
Latence d'inférence	technique	compatible interactif	non applicable	58,22 ms par article
Rejeu complet de la chaîne	technique	une commande	vérifié en intégration continue	vérifié

Une seule erreur subsiste dans la part automatisée du jeu de test, sur 135 articles traités sans intervention. Le seuil transforme donc un modèle à deux erreurs en un service dont l'erreur résiduelle automatisée est unitaire, au prix de 14,6 % du volume envoyé en revue.

Risques et opportunités.

Risque	Portée	Levier d'atténuation
Étalon déclaratif bruité	plafonne toute performance mesurable	faire arbitrer un échantillon par l'équipe catalogue, en priorité les cas où le modèle contredit le vendeur avec confiance (U3)
Corpus artificiellement équilibré, 7 × 150	performance non transposable telle quelle	réévaluer sur un extrait réel du catalogue avant mise en service
Photographies de catalogue soignées	dégradation probable sur des prises de vue vendeurs	mesurer sur un lot de photographies non retouchées
Dépendance à un extracteur pré-entraîné externe	rupture de disponibilité ou de licence	artefact figé et versionné localement ; TF-IDF seul comme repli, à écart nul à cette précision
Dérive du catalogue, nouvelles familles de produits	perte de justesse silencieuse	surveillance du taux d'automatisation, seuil d'alerte, réentraînement planifié
Concentration du coût sur l'extraction d'image	coût d'exploitation	traitement par lots, cache des caractéristiques, ou bascule sur le texte seul

Opportunité	Effet attendu
Le seuil est un paramètre métier	arbitrage automatisation contre justesse révisable sans réentraînement
Les probabilités servent trois cas d'usage	U2 et U3 sans développement supplémentaire
La modalité image est séparable	deux niveaux de service, économique ou complet
Chaîne rejouable en une commande	réentraînement à coût marginal une fois le corpus ré-étiqueté

Scénarios budgétaires. Estimation, adossée aux mesures de la partie 3.4 et exprimée en journées-homme ; aucun devis n'a été demandé à un fournisseur.

Scénario	Périmètre	Charge estimée	Infrastructure	Inférence, 100 000 articles
A. Démonstrateur, état actuel	interface de démonstration, modèle sérialisé	réalisé	hébergement mutualisé, coût nul	1,62 h de calcul
B. Mise en service progressive	interface authentifiée, seuil paramétrable, journalisation	10 à 15 j	une instance de calcul standard	1,62 h de calcul, par lots nocturnes
C. Industrialisation complète	B, plus surveillance de dérive, réentraînement outillé, interface de revue	30 à 40 j	instance de calcul, stockage des journaux, tableau de bord	idem, avec réentraînement périodique

Le scénario B suffit à ouvrir la valeur des cas d'usage U1 à U3. Le scénario C ne se justifie qu'une fois le volume et la dérive observés.

Impacts et leviers.

Impact	Analyse	Levier
Légal et réglementaire	corpus sans donnée personnelle ; images sous licence de recherche, non réutilisables en production	constituer un corpus propre à l'entreprise avant mise en service
Biais	la référence reproduit les habitudes de saisie des vendeurs ; l'équilibre 7 × 150 est artificiel	ré-étiquetage d'un échantillon arbitré ; réévaluation sur distribution réelle
Biais de nomenclature	les frontières <i>Home Decor</i> , <i>Home Furnishing</i> , <i>Baby Care</i> sont culturelles avant d'être visuelles	arbitrage explicite et documenté par l'équipe catalogue
Sécurité	descriptions et images sont des entrées non maîtrisées	validation des formats et des tailles en entrée, interface authentifiée, journalisation des accès
Latence	58,22 ms par article, dominés par l'extraction d'image	traitement par lots ; repli texte seul si un appel interactif est exigé
Organisationnel	14,6 % du volume en revue humaine, charge nouvelle et non affectée	dimensionner la file de revue avant mise en service, outiller la correction
Confiance des vendeurs	une proposition automatique contredisant la saisie peut être mal reçue	proposition et non imposition, motif affiché, possibilité de refus tracée

5. Contrôle et suivi du projet

5.1 Tableau de bord de pilotage

Indicateur	Source	Valeur de fin de projet
Avancement	jalons publiés du dépôt	6 phases sur 6 du périmètre réalisées, 7 versions étiquetées
Délais	historique du dépôt	4 lots de travail livrés, chacun sur sa branche puis fusionné
Livrables	dépôt et documentation	3 scripts d'exécution, 6 carnets exécutés, rapport, démonstrateur en ligne
Qualité des données	profilage et contrôles	1 fuite détectée et neutralisée, 2 anomalies de format corrigées
Qualité logicielle	intégration continue	23 tests, dont un test anti-fuite ; lint et format vérifiés à chaque poussée
Performances	jeu réservé, une ouverture	F1 macro 0,987, 156 / 158
Coût de calcul	mesure locale	chaîne complète rejouée en environ 20 minutes, sans coût d'infrastructure

Méthodologie de gestion. Flux de travail à trois niveaux : `main` porte les versions publiées, `develop` intègre, chaque lot vit sur sa propre branche avant fusion. Versions sémantiques, étiquetées à chaque livraison. Intégration continue déclenchée sur les trois niveaux. Un correctif urgent a suivi le chemin dédié (`hotfix/`), après détection d'un défaut de collecte des tests depuis un clone vierge.

5.2 Outils et processus de suivi

Méthodologie de test.

Niveau	Objet	Dispositif
Unitaire	découpe, métriques, fusion, vectorisation, optimisation	23 tests, exécutés à chaque poussée
Intégrité du protocole	les trois parts sont disjointes	test dédié, échoue si une fuite apparaît
Reproductibilité	la chaîne se rejoue depuis un clone vierge	tâche d'intégration continue distincte
Non-régression numérique	le modèle rechargé depuis le disque reproduit le résultat publié	vérification à la sérialisation, artefact supprimé en cas d'écart
Bout en bout	interface de démonstration sur articles jamais vus	démonstrateur conteneurisé, en ligne

Contrôles ayant effectivement corrigé le projet. Deux erreurs de méthode ont été détectées et corrigées en cours de route, aucune n'ayant été signalée par un test en échec : le code fonctionnait, il

mesurait autre chose que ce qui était visé.

Erreur	Détection	Correction	Conséquence
Comparaison des stratégies d'augmentation lue sur le jeu de test	revue du protocole	sélection reportée sur la validation	configuration retenue modifiée : le test désignait l'absence d'augmentation, la validation désigne l'augmentation douce
Standardisation par dimension avant projection	accord TF-IDF tombé à 0,001, au niveau du hasard	normalisation ligne à ligne	accord TF-IDF rétabli à 0,325

Chaque chiffre du rapport est pour cette raison accompagné de son protocole, et certains sont rapportés deux fois.

Suivi en production, proposé.

Objet	Indicateur	Déclencheur
Justesse perçue	taux de refus des propositions par les vendeurs	dépassement du niveau de référence
Automatisation	part du volume au-dessus du seuil	baisse durable du taux
Dérive des entrées	distribution des confiances maximales	déplacement de la distribution
Charge de revue	volume en file, délai d'écoulement	file non résorbée
Disponibilité	latence et taux d'erreur de l'interface	seuils d'exploitation

6. Conclusion et recommandations

Choix clés. L'information nécessaire à la catégorisation est présente dans les données déjà fournies par les vendeurs : la faisabilité est établie avant tout engagement. Le comparatif à protocole constant désigne la fusion TF-IDF ⊕ DINOv2, qui obtient 0,987 de F1 macro et 156 articles sur 158 sur un jeu réservé ouvert une seule fois. La décision est séparée du modèle par un seuil de confiance choisi sur la validation, qui automatise 85,4 % du volume avec 0,993 de propositions correctes. Les modèles récents n'apportent pas systématiquement un gain : net en vision, nul ici sur le texte figé, où une référence lexicale reste en tête.

Recommandations, par ordre de priorité.

1. Faire arbitrer par l'équipe catalogue les frontières ambiguës, et ré-étiqueter en priorité les articles où le modèle contredit le vendeur avec une confiance élevée.
2. Mettre en service le scénario B : interface authentifiée, seuil paramétrable, journalisation des prédictions et des confiances.

3. Dimensionner et outiller la file de revue humaine avant l'ouverture du service, 14,6 % du volume étant concerné.
4. Réévaluer la performance sur un extrait réel du catalogue, à distribution non équilibrée et photographies non retouchées, avant tout engagement de niveau de service.
5. Constituer un corpus propre à l'entreprise, les images d'étude étant sous licence de recherche.
6. Traiter la qualité des métadonnées externes avant d'envisager l'élargissement de gamme.

Perspectives. Réglage fin des extracteurs sur corpus élargi ; classification sur la nomenclature complète ; augmentation d'images différenciée par type de produit plutôt qu'uniforme ; recherche d'articles visuellement similaires, qui réutiliserait les représentations déjà calculées.

Prochaines étapes. Arbitrage du scénario budgétaire par le commanditaire, puis planification des phases 7 à 9 avec l'équipe plateforme. La chaîne est rejouable en une commande : le réentraînement sur corpus ré-étiqueté n'a pas de coût de développement.

Annexes

A. Rejeu de l'étude

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements-encoders.txt
```

```
python faisabilite.py           # les huit représentations, projections, partition
python supervise_image.py      # classification supervisée et augmentation
python collecte_api.py         # collecte « champagne » et fichier CSV
python scripts/comparer_modernes.py # le comparatif des représentations et la fusion
python scripts/seuil_confiance.py # seuil de décision et indicateurs d'automatisation
python scripts/cout_inference.py # coût d'inférence, poste par poste
python scripts/schemas.py     # les deux schémas de flux et d'architecture
```

Le socle seul (`requirements.txt`) suffit pour l'exploration des données et les modèles classiques ; `requirements-encoders.txt` ajoute les réseaux pré-entraînés, soit environ 3 Go de poids au premier lancement. Les versions sont épinglées, la graine aléatoire est fixe, et la découpe des données est définie dans un module unique (`src/pipeline.py`) appelé par tous les scripts. Les caractéristiques extraites sont mises en cache sur disque : une seconde exécution ne recalcule ni SIFT ni les réseaux.

B. Figures et fichiers produits

Fichier	Contenu
<code>reports/fig3_transformations.png</code>	La chaîne de transformation du texte, sur un article réel
<code>reports/fig4_donnees.png</code>	Équilibre des classes et distribution des longueurs
<code>reports/fig5_projections.png</code>	Les huit projections en deux dimensions
<code>reports/fig6_clusters.png</code>	VGG16 : catégories réelles et groupes trouvés
<code>reports/fig7_ari.png</code>	L'accord entre groupes et catégories, par représentation
<code>reports/fig8_confusion_image.png</code>	Matrice de confusion du modèle supervisé image
<code>reports/fig9_augmentation_par_classe.png</code>	L'effet de l'augmentation, catégorie par catégorie
<code>reports/fig10_comparaison_par_classe.png</code>	F1 par catégorie des six configurations comparées
<code>reports/fig11_flux_actuel.png</code>	Le processus de catégorisation en place
<code>reports/fig12_architecture_cible.png</code>	L'architecture cible et son socle technique
<code>reports/faisabilite.csv</code>	Dimensions et accords des huit représentations
<code>reports/supervise_image_validation.csv</code>	Comparaison des stratégies d'augmentation
<code>reports/supervise_image_test.csv</code>	Résultat final du modèle image retenu
<code>reports/comparaison_validation.csv</code>	Le comparatif des représentations, sur la validation
<code>reports/comparaison_test.csv</code>	L'évaluation finale de la fusion, sur le jeu réservé
<code>reports/seuil_confiance.csv</code>	Automatisation et justesse par seuil, validation et test
<code>reports/cout_inference.json</code>	Coût d'inférence par poste et par volume
<code>reports/produits_champagne.csv</code>	Les dix produits collectés via l'interface externe

C. Ressources du projet

Ressource	Adresse
Dépôt du projet	https://github.com/richardhugou/product-category-classifier
Démonstrateur en ligne	https://huggingface.co/spaces/trikwi/projet55
Portfolio	https://portfolio.richardh.fr
Description du dépôt	<code>README.md</code>
Carnets exécutés, dans l'ordre de la mission	<code>notebooks/</code>

D. Notes techniques

Universal Sentence Encoder et la cohabitation TensorFlow et PyTorch. USE est distribué pour TensorFlow, quand le reste de la chaîne repose sur PyTorch. Chargées dans un même processus, les deux bibliothèques se sont bloquées mutuellement sans lever d'erreur ; isolé dans son propre processus, le modèle se charge en deux secondes. L'encodage USE est donc délégué à un sous-processus dédié, ce qui permet d'employer le modèle de référence lui-même. Par ailleurs, `tensorflow_hub` importe encore `pkg_resources`, retiré de `setuptools` à partir de la version 81 : la borne haute des dépendances est là pour cette seule raison.

Point d'entrée de l'interface Open Food Facts. L'ancien point d'entrée `cgi/search.pl`, déprécié, a renvoyé une erreur de service lors du premier essai. Le script utilise le point d'entrée v2, maintenu, et réessaie avec une attente croissante.

Normalisation avant projection. Chaque article est ramené à une longueur unitaire avant l'ACP, ce qui rend la distance euclidienne équivalente à la distance cosinus. La standardisation par dimension, testée d'abord, amplifiait les termes rares au point de ramener l'accord TF-IDF au niveau du hasard.

Mesure du coût d'inférence. Latences mesurées sur poste local, accélérateur intégré, sur un échantillon de 16 photographies pour l'extraction et sur les 158 articles du jeu réservé pour le texte et la tête de classification. Un passage à blanc précède la mesure pour ne pas compter l'allocation initiale.