

Automatisation de la catégorisation d'articles sur une place de marché

Rapport de conduite de projet AI Engineering

Richard Hugou · Data Scientist & AI Engineer
août 2026

Projet technique : github.com/richardhugou/product-category-classifier

Portfolio : portfolio.richardh.fr

1. Contexte et besoin

1.1 Contexte

La place de marché étudiée laisse au vendeur le choix de la catégorie lors de la mise en ligne d'un article. Les informations disponibles sont une description, une photographie et plusieurs champs déclaratifs.

Le catalogue est en croissance. Aucun modèle de catégorisation ni dispositif de contrôle qualité n'est en place. Le projet est réalisé sur poste local, à partir d'un échantillon de **1 050 articles répartis en 7 catégories**.

Enjeu principal : proposer automatiquement une catégorie à partir des informations déjà fournies par le vendeur.

Contraintes retenues : - premier niveau de nomenclature uniquement ; - calcul local ; - solution reproductible et transportable ; - proposition de catégorie, sans décision imposée au vendeur ; - corpus d'étude sans donnée personnelle ; - images sous licence de recherche.

1.2 Besoin métier

Le brief du commanditaire comporte trois demandes :

1. vérifier que la catégorie peut être retrouvée à partir du texte et de l'image ;
2. construire et évaluer une classification supervisée à partir des images ;
3. tester la collecte de nouveaux produits via une source externe.

L'analyse initiale des données ajoute deux exigences : - exclure les variables susceptibles de créer une fuite ; - harmoniser les formats d'image.

Objectif	Indicateur
Établir la faisabilité	accord entre groupes non supervisés et catégories
Comparer les solutions	F1 macro sur validation
Évaluer le modèle retenu	F1 macro et exactitude sur test
Limiter les décisions incertaines	taux d'automatisation et justesse après seuil
Garantir le rejeu	pipeline exécutable depuis un dépôt vierge


Périmètre retenu : catégorisation sur 7 classes, comparaison texte/image, fusion multimodale, seuil d'abstention et collecte externe.

Hors périmètre : classification hiérarchique complète, fine-tuning des extracteurs, interface de correction catalogue.

2. Audit de l'existant

2.1 Processus actuel

La catégorie est saisie par le vendeur puis utilisée directement pour le filtrage du catalogue. Aucun contrôle intermédiaire n'est prévu.



Étape	Situation
Saisie	catégorie déclarée par le vendeur
Stockage	arborescence de catégories
Restitution	filtrage sur le premier niveau
Contrôle qualité	aucun

2.2 Données disponibles

Chaque article contient notamment : - `product_name` ; - `description` ; - `product_category_tree` ; - une photographie.

Exemple utilisé comme référence dans l'étude :

Champ	Exemple
<code>product_name</code>	V9 METAL STRAP Analog Watch – For Men
<code>description</code>	fiche de spécifications en anglais
<code>product_category_tree</code>	Watches >> Wrist Watches >> ...
<code>image</code>	1 152 × 1 816 px


Le premier niveau de `product_category_tree` fournit les 7 classes du projet : *Baby Care, Beauty and Personal Care, Computers, Home Decor & Festive Needs, Home Furnishing, Kitchen & Dining, Watches*.

La catégorie reste une **étiquette déclarative** : elle peut contenir des erreurs.

2.3 Audit des entrées

Les descriptions sont des fiches de spécifications plutôt que du texte rédigé : - 13 à 587 mots ; - médiane : 44 mots ; - longueur médiane différente selon les catégories.

Les photographies sont hétérogènes : - 890 tailles distinctes sur 1 050 fichiers ; - ratios de 0,23 à 4,36 ; - jusqu'à 93 mégapixels.



Fuite détectée

Le champ **brand** contient **32 % de valeurs manquantes**. Ces absences sont concentrées sur trois classes :

- *Watches* : 140 / 150 ;
- *Beauty and Personal Care* : 109 / 150 ;
- *Kitchen & Dining* : 71 / 150.

Le champ est exclu, indicateur d'absence compris. Son utilisation aurait permis d'apprendre un comportement de saisie plutôt que le contenu du produit.

Écarts principaux

Écart	Conséquence
aucune mesure de justesse	qualité du catalogue non pilotée
nomenclature appliquée librement	incohérences entre vendeurs
texte et image non contrôlés	entrées hétérogènes
étiquettes déclaratives	référence d'évaluation imparfaite

3. Solution technique

3.1 Cas d'usage retenus

Priorisation selon valeur métier, faisabilité mesurée et effort de mise en œuvre.

Cas d'usage	Décision
proposer une catégorie à la mise en ligne	retenu
s'abstenir sous un seuil de confiance	retenu
signaler les contradictions modèle / vendeur	retenu
collecter de nouveaux produits	étudié séparément
classifier toute la nomenclature	reporté
recherche visuelle de produits similaires	hors périmètre

Les trois premiers cas d'usage reposent sur le même modèle.

3.2 Faisabilité sur les représentations


La première étape vérifie si les catégories sont déjà structurées dans les données, sans apprentissage supervisé.

Huit représentations sont comparées : - texte : comptage, bigrammes, TF-IDF, Word2Vec, BERT, USE ; - image : SIFT + BoVW, VGG16.

Réduction : ACP à 50 composantes, puis t-SNE pour la visualisation.

Après réduction et partitionnement en 7 groupes, l'accord avec les catégories est mesuré par l'**indice de Rand ajusté (ARI)**. L'ARI est également calculé dans l'espace de représentation original afin de contrôler l'effet de la réduction.

Représentation	Modalité	ARI projection	ARI espace complet
VGG16	image	0,510	0,540
USE	texte	0,440	0,333
TF-IDF	texte	0,325	0,214
Comptage + bigrammes	texte	0,316	0,227
BERT	texte	0,316	0,288
Comptage de mots	texte	0,306	0,270
Word2Vec	texte	0,300	0,207
SIFT + BoVW	image	0,044	0,056



Constat : l'information de catégorie est présente dans les données. VGG16 produit la structure la plus nette en image ; USE est la meilleure représentation texte de cette étape non supervisée.

La confusion la plus visible concerne *Home Furnishing* et *Baby Care*, notamment pour des textiles photographiés dans des conditions proches.

3.3 Benchmark supervisé 2026


Le benchmark compare les représentations dans un protocole commun :

- **735** articles d'entraînement ;
- **157** de validation ;
- **158** de test ;
- extracteurs pré-entraînés figés ;
- MLP à une couche cachée de 256 neurones ;
- une instance de MLP entraînée indépendamment pour chaque représentation ;
- sélection au **F1 macro sur validation**.

Représentation	Modalité	F1 macro validation
TF-IDF	texte	0,937
DINOv2	image	0,912
BERT	texte	0,905
ModernBERT	texte	0,904
VGG16	image	0,822

Texte : BERT et ModernBERT n'apportent pas d'avantage par rapport à TF-IDF dans ce protocole.

Image : DINOv2 améliore nettement les performances par rapport à VGG16, avec environ **+9 points de F1 macro**.



Fusion multimodale

Les deux meilleures représentations par modalité sont concaténées : - TF-IDF : 4 532 caractéristiques ; - DINOv2 : 1 536 caractéristiques ; - représentation finale : 6 068 caractéristiques.

Configuration	F1 macro validation
TF-IDF	0,937
TF-IDF ⊕ DINOv2	0,937

Les deux résultats sont **quasi identiques**. Aucun gain moyen de la fusion n'est établi sur la validation.

La fusion est retenue par la règle de sélection fixée pour le benchmark, puis évaluée sur le jeu de test :

- **F1 macro : 0,987**
- **exactitude : 156 / 158**
- **2 erreurs**

Le score test est rapporté comme résultat sur cet échantillon de 158 articles, sans extrapolation à un catalogue réel.

3.4 Classification image et data augmentation

La demande image seule est traitée séparément avec VGG16 figé.


Quatre configurations sont comparées sur la validation :

Stratégie	F1 macro validation
augmentation douce x4	0,828
augmentation forte x4	0,827
sans augmentation	0,822
augmentation forte x8	0,815

L'écart maximal est de **0,006**. Aucun bénéfice général de la data augmentation n'est établi.


Sur le protocole corrigé, la configuration retenue est évaluée sur test :

- **F1 macro : 0,867**
- **exactitude : 137 / 158**



Les confusions *Baby Care* / *Home Furnishing* observées en non supervisé restent visibles en classification.

3.5 Architecture cible



Chaîne proposée :

texte + image → prétraitements → TF-IDF + DINOv2 → fusion → MLP → score → seuil → catégorie ou revue

Principaux choix :

Choix	Motif
extracteurs figés	comparaison contrôlée des représentations
MLP 256 identique	isoler l'effet de la représentation
seuil séparé du modèle	décision métier modifiable sans réentraînement
artefact sérialisé	transport et rejou simplifiés
conteneurisation	environnement reproductible

Coût d'inférence

Poste	Temps par article
DINOv2	58,09 ms
TF-IDF	0,10 ms
MLP	0,02 ms
Total	58,22 ms

L'extraction DINOv2 représente l'essentiel du coût. TF-IDF seul conserve un F1 de validation équivalent à la précision affichée pour un coût très inférieur.

3.6 Collecte externe

Open Food Facts est utilisé pour tester une collecte sur l'épicerie fine.

Résultat : - 10 produits ; - 5 champs collectés ; - 2 compositions manquantes.

Les catégories obtenues sont hétérogènes, parfois non traduites ou peu informatives. La collecte est techniquement réalisable, mais la qualité des métadonnées doit être traitée avant tout usage d'apprentissage.

4. Mise en œuvre et aide à la décision

4.1 Démarche projet

Le projet est découpé en lots courts, versionnés dans Git.

Phase	Contenu	État
Audit	profilage, cible, fuite	réalisé
Faisabilité	représentations, projection, ARI	réalisé
Benchmark	cinq représentations, fusion	réalisé
Qualité	tests, CI, anti-fuite	réalisé
Démonstrateur	interface trois modalités	réalisé
Documentation	README, rapport, notebooks	réalisé
Mise en service	authentification, seuil, logs	proposé
Surveillance	dérive et taux d'automatisation	proposé
Réentraînement	corpus ré-étiqueté	proposé

Outils principaux : pandas, scikit-learn, PyTorch, Transformers, pytest, GitHub Actions, Streamlit, Docker.

4.2 Seuil de décision

Le modèle ne doit pas nécessairement décider pour tous les produits.

Le seuil est choisi sur la validation avec une cible de **99 % de propositions correctes sur la part automatisée**.

Seuil retenu : **0,60**.

Indicateur	Validation	Test
taux d'automatisation	84,1 %	85,4 %
justesse sur la part automatisée	99,2 %	99,3 %
revue humaine	25 / 157	23 / 158

Le modèle automatise donc environ **85 %** du volume et transfère le reste en revue humaine.

4.3 Risques

Risque	Mesure proposée
étiquettes vendeurs bruitées	revue d'un échantillon par l'équipe catalogue
corpus équilibré artificiellement	nouvelle évaluation sur catalogue réel
photographies trop propres	test sur photographies vendeurs
coût de DINOv2	batch, cache ou mode texte seul
dérive du catalogue	suivi du taux d'automatisation et des confiances
entrées libres	validation des formats et tailles
charge de revue humaine	dimensionnement avant mise en service
licence des images d'étude	constitution d'un corpus propre à l'entreprise

Scénarios

Scénario	Périmètre	Charge
Démonstrateur	état actuel	réalisé
Mise en service	interface authentifiée, seuil, logs	à estimer
Industrialisation	monitoring, réentraînement, revue	à estimer

Aucun chiffrage de charge n'a été produit dans le cadre du projet.

5. Contrôle et suivi

5.1 Pilotage

Indicateur	État final
périmètre	6 phases réalisées
versions	7 versions étiquetées
livrables	scripts, notebooks, rapport, démonstrateur
qualité des données	1 fuite neutralisée, anomalies de format corrigées
qualité logicielle	23 tests + lint + CI
performance finale	F1 macro 0,987 · 156 / 158
coût de calcul	rejeu complet ≈ 20 min sur poste local

Gestion Git : - `main` : versions publiées ; - `develop` : intégration ; - branches dédiées par lot ; - correctifs via `hotfix/` .

5.2 Tests et reproductibilité

Niveau	Contrôle
unitaire	découpe, métriques, fusion, vectorisation
anti-fuite	train / validation / test disjoints
reproductibilité	rejeu depuis clone vierge
non-régression	artefact rechargé = résultat publié
bout en bout	démonstrateur conteneurisé

Deux corrections méthodologiques ont été documentées :

1. une première comparaison des stratégies d'augmentation avait été lue sur le test ; la sélection a été déplacée sur la validation ;
2. une standardisation par dimension dégradait fortement l'ARI TF-IDF ; elle a été remplacée par une normalisation ligne à ligne.

Ces erreurs n'étaient pas des erreurs d'exécution : le code fonctionnait, mais le protocole devait être corrigé.

Suivi proposé en production

- taux de refus des propositions ;

- part du volume automatisée ;
 - distribution des scores de confiance ;
 - volume et délai de la file de revue ;
 - latence et taux d'erreur du service.
-

6. Conclusion et recommandations

La faisabilité de la catégorisation automatique est établie sur le corpus étudié.

Le benchmark 2026 montre deux résultats principaux :

- **texte** : TF-IDF reste devant BERT et ModernBERT dans le régime figé ;
- **image** : DINOv2 améliore nettement VGG16.

La fusion TF-IDF $\oplus$ DINOv2 ne montre pas de gain moyen sur la validation, mais constitue la configuration retenue par la règle de sélection du benchmark. Sur le test, elle atteint **0,987 de F1 macro et 156 / 158 classifications correctes**.

Le seuil de confiance permet de transformer le classifieur en service avec abstention : **85,4 %** du volume est automatisé sur le test, avec **99,3 %** de propositions correctes sur cette partie.

Recommandations

1. Réévaluer la solution sur un échantillon réel du catalogue, non équilibré et avec des photographies vendeurs.
 2. Faire arbitrer et ré-étiqueter un échantillon des catégories ambiguës.
 3. Dimensionner la revue humaine avant mise en service.
 4. Mettre en place authentification, validation des entrées et journalisation.
 5. Sur un corpus élargi, tester le fine-tuning de BERT / ModernBERT / DINOv2.
 6. Répéter les expériences sur plusieurs splits ou seeds afin de quantifier l'incertitude.
 7. Réévaluer ensuite l'intérêt de la fusion multimodale.
 8. Étendre à la classification hiérarchique uniquement après validation sur le premier niveau.
-

Annexes

A. Rejeu

```
python -m venv .venv && source .venv/bin/activate  
pip install -r requirements-encoders.txt
```

```
python faisabilite.py  
python supervise_image.py  
python collecte_api.py  
python scripts/comparer_modernes.py  
python scripts/seuil_confiance.py  
python scripts/rapport_classification.py  
python scripts/cout_inference.py  
python scripts/schemas.py
```

Versions épinglées, graine fixe, split centralisé dans `src/pipeline.py`, caractéristiques mises en cache.

B. Figures

- `fig4_donnees.png` : équilibre des classes et longueurs ;
- `fig5_projections.png` : projections des représentations ;
- `fig8_confusion_image.png` : confusion image ;
- `fig10_comparaison_par_classe.png` : F1 par catégorie ;
- `fig11_flux_actuel.png` : processus existant ;
- `fig12_architecture_cible.png` : architecture cible.

C. Ressources

- Dépôt : `github.com/richardhugou/product-category-classifier`
- Démonstrateur : `huggingface.co/spaces/trikwi/projet55`
- Portfolio : `portfolio.richardh.fr`
- Notebooks : `notebooks/`

D. Précision et rappel par catégorie

Modèle retenu, jeu de test, `reports/classification_test.csv`.

Catégorie	Précision	Rappel	F1	Articles
Baby Care	0,957	1,000	0,978	22
Beauty and Personal Care	1,000	0,955	0,977	22
Computers	1,000	1,000	1,000	23
Home Decor & Festive Needs	1,000	0,957	0,978	23
Home Furnishing	0,958	1,000	0,979	23
Kitchen & Dining	1,000	1,000	1,000	22
Watches	1,000	1,000	1,000	23
Moyenne macro	0,988	0,987	0,987	158

Valeurs exactes de la fusion sur validation, pour traçabilité : TF-IDF 0,9365, fusion 0,9366 ([reports/comparaison_validation.csv](#)).